

חיזוי ויעול מלאי חברת 'סין' - כריית מידע



מגייסים:
נפתלי כהן
אליאור פולק
מנחה:
מר אורן גלבוע

רקע על הארגון



החברה הראשתונה והיחידה שמציעה לייזר מסחרי המבוסס על CBC.

01

בל טכנולוגיות הליבה מפותחות בתחום החברה, עם יותר מ-90 פטנטים.

02

כ-200 עובדים הממוקמים בירושלים, ישראל.

03

לייזרים נמכרים לתעשייה הרכבת, מספנות ומרכזי מחקר.

04

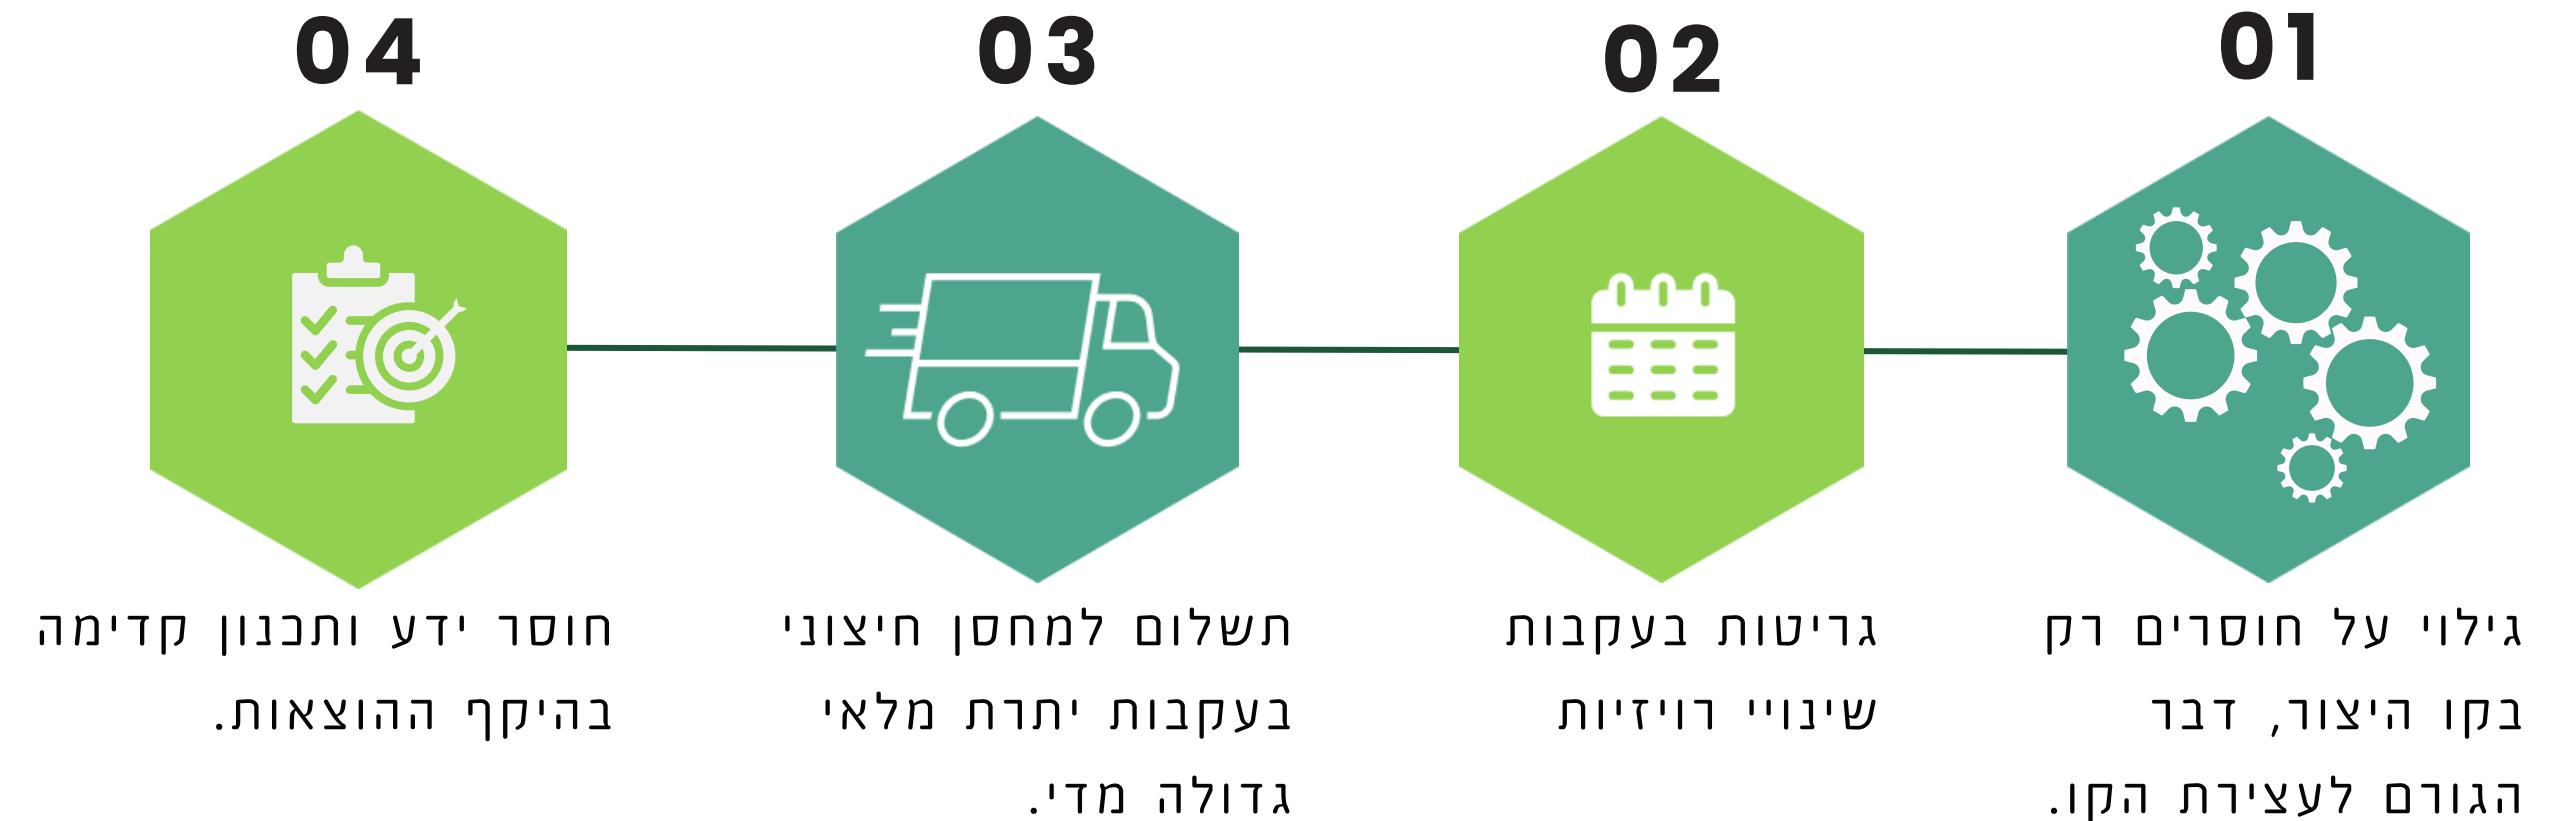


תיאור המצב הנוכחי

בסיון, ישנו פריטים המנוהלים בשיטת "מינימום-מקסימום".

פריטים אלו נמצאים בשימוש נרחב לפרויקטים רבים, ואינם ייחודיים לפרויקט מסוים.

קבוצת הפריטים האופטיים-קריטיים וחיווניים עברו הייצור, ובלעדיהם לא ניתן להמשיך בתהילין הייצור.



סיום

דשبورד ו-DI

חיזיון

BI

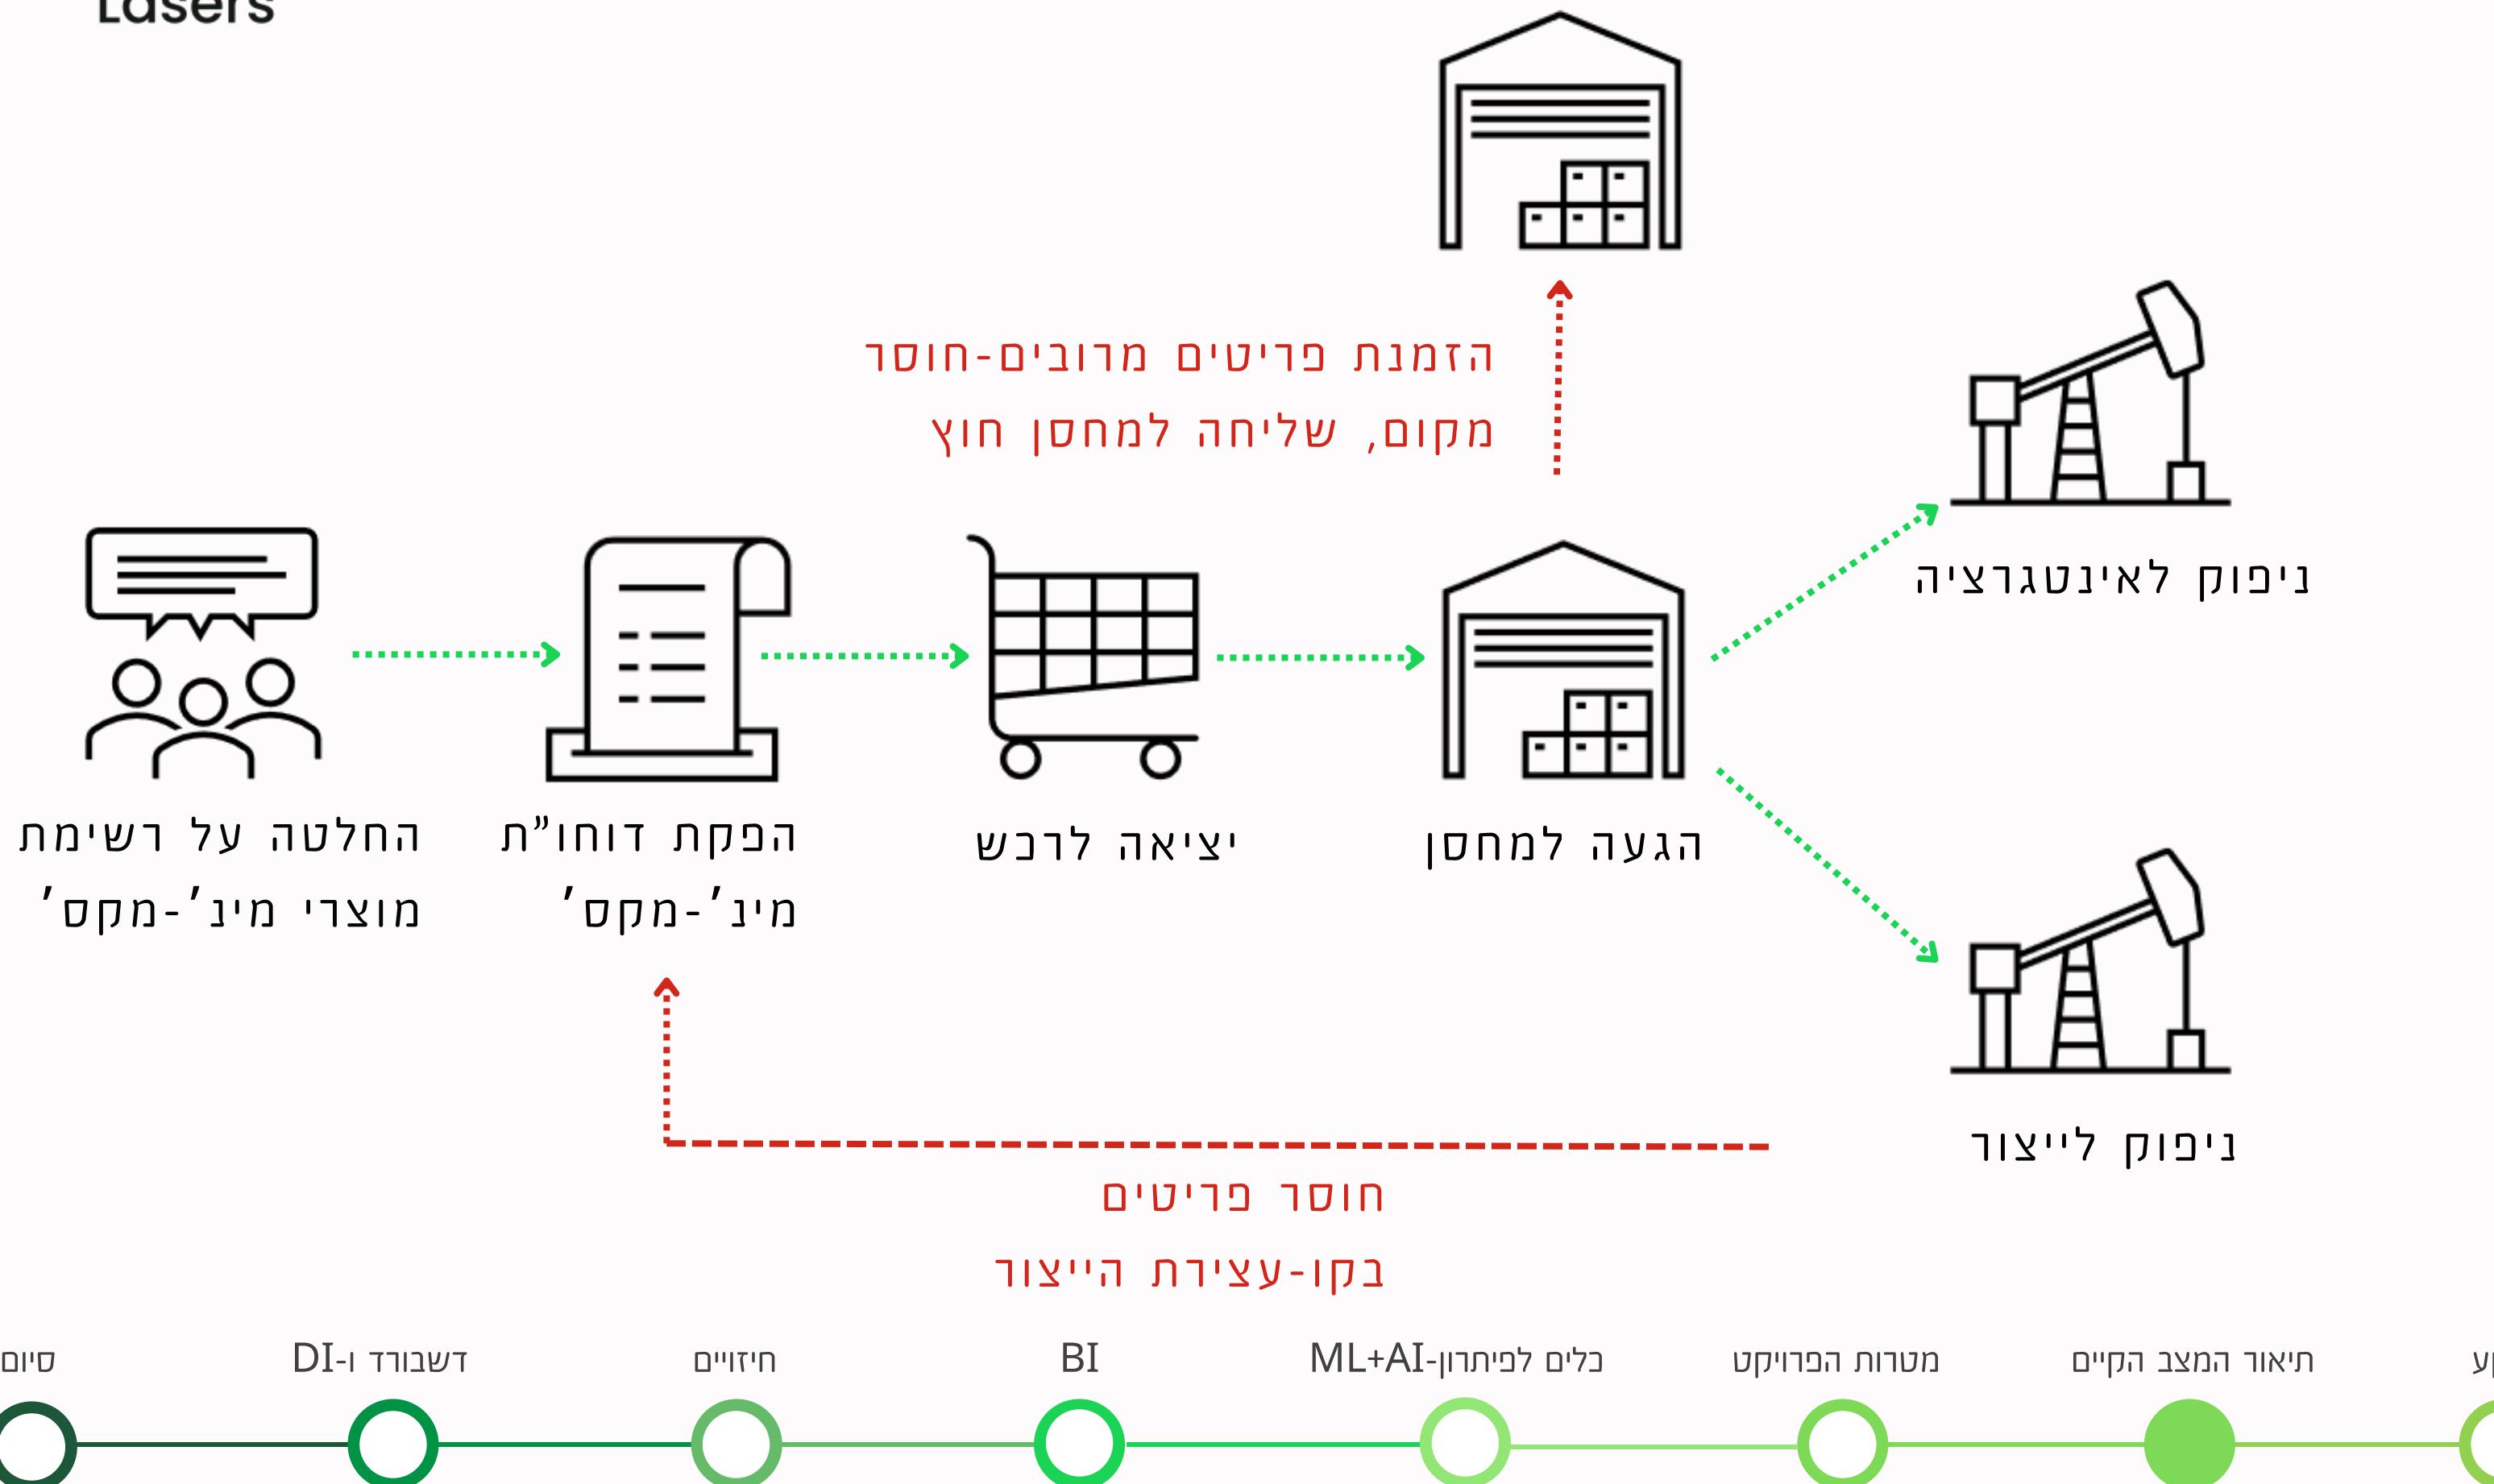
כליים לפיתוח-AI+ML

מטרות הפרויקט

תיאור המצב הנוכחי

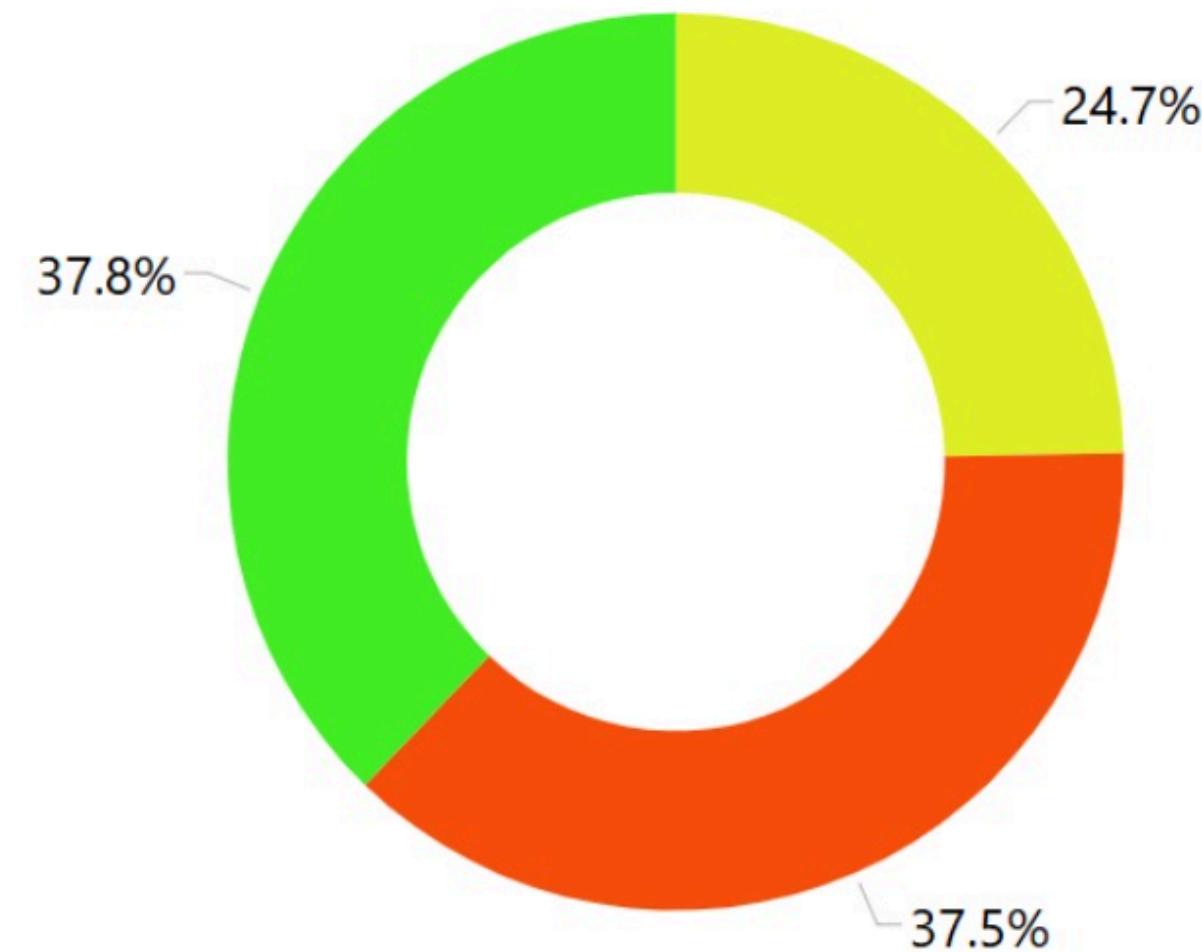
רקע

תרשים זרימה-מצריי מין'-מקום'

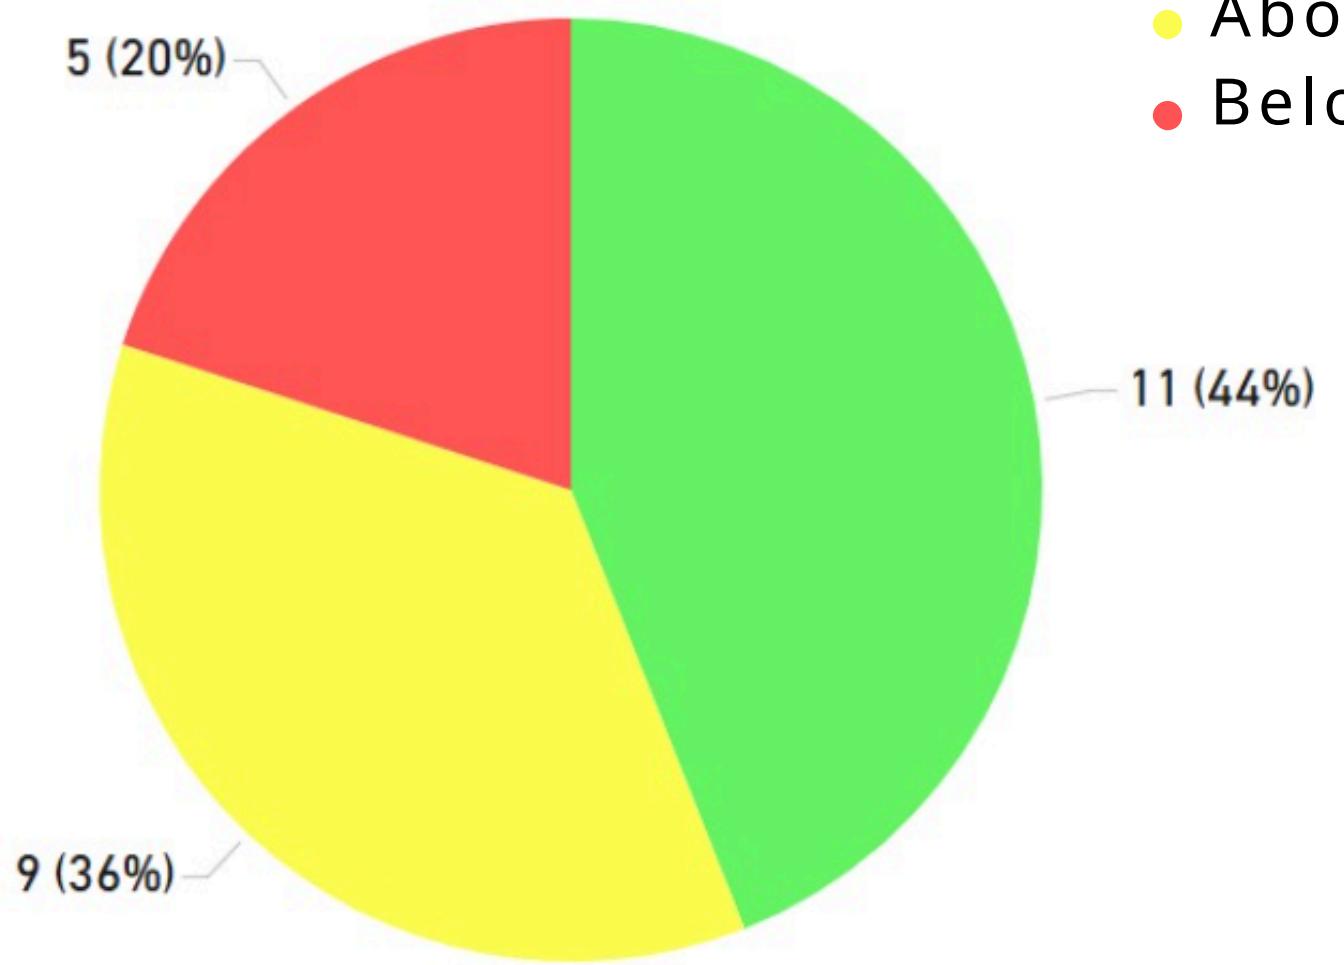


בעיות במצב הקאים-אופטיקות

Continuous Inventory In-Range



Inventory Status



- Within Range
- Above Max
- Below Min

אחוז סך החיריגות לאורן השניים



מס' הפריטים החורגים

מטרות הפרויקט



מתן תחזית צריכה, צפי כספי והטמעת המודל



מחקר מודלים מבוסס AI ולמידת מבוגנה ובחירה מודל אופטימלי

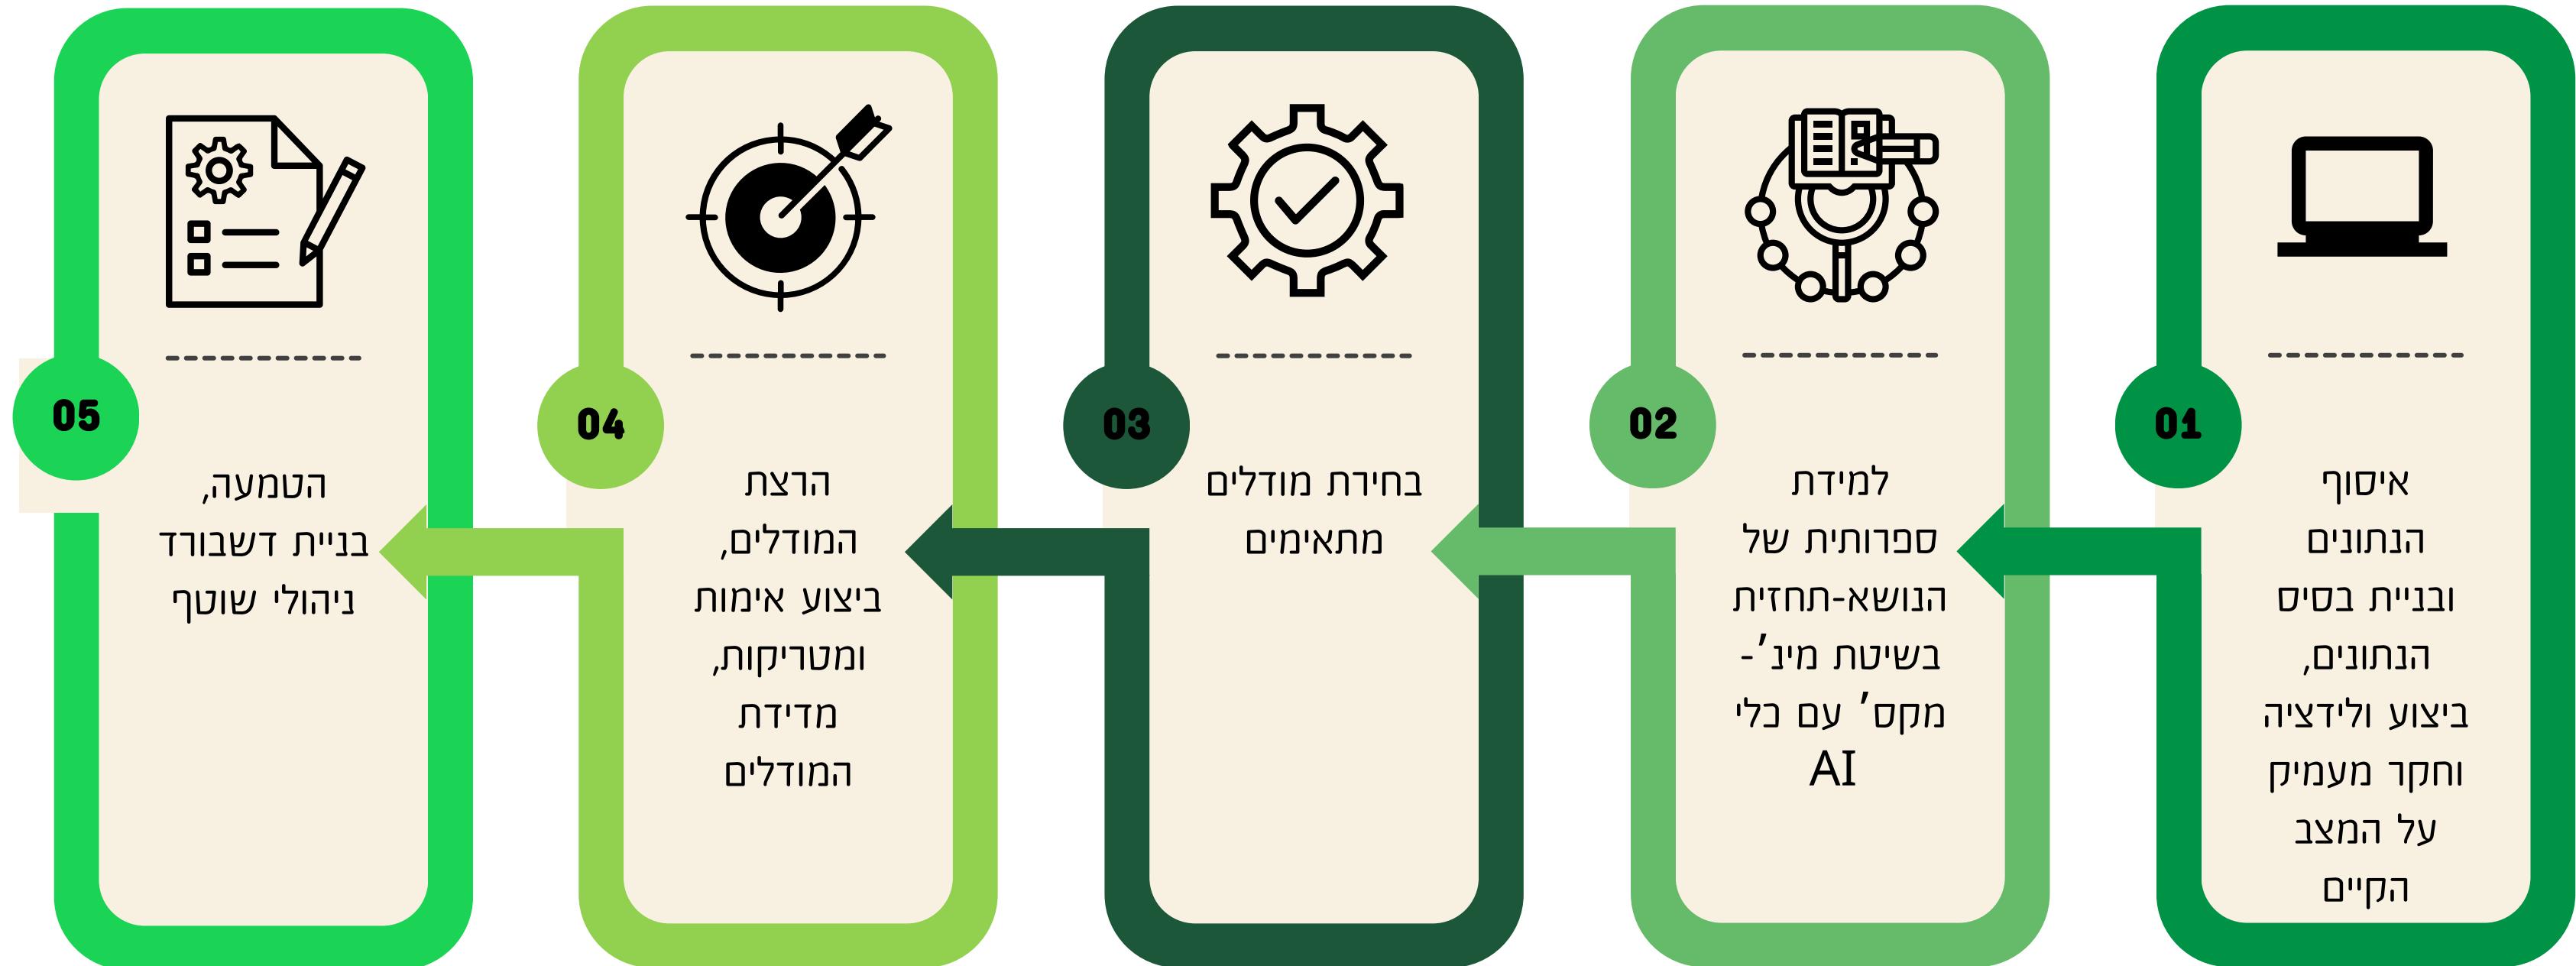


BI - הקיימן המצב

קביעת מzd להצלחה-בנויות מודל ש חוזה את צדרכות הפריטים, ומודל ניהול מלאי המשפר את המצב הנוכחי



שיטות וכליים לפיתרון



סיום

דשborad + DI

חיזויים

BI

כלים לפיתרון-AI+ML

מטרות הפרויקט

תיאור המצב הנוכחי

רקע

ETL - תהליך הנחתוניים-בנין בסיס

Extract - קישור בין טבלאות
ע"י שאלות SQL



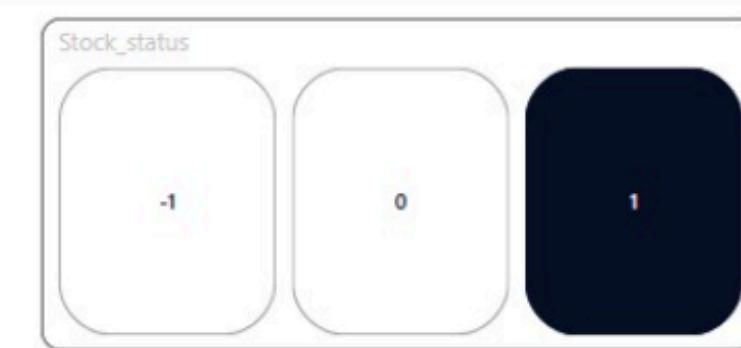
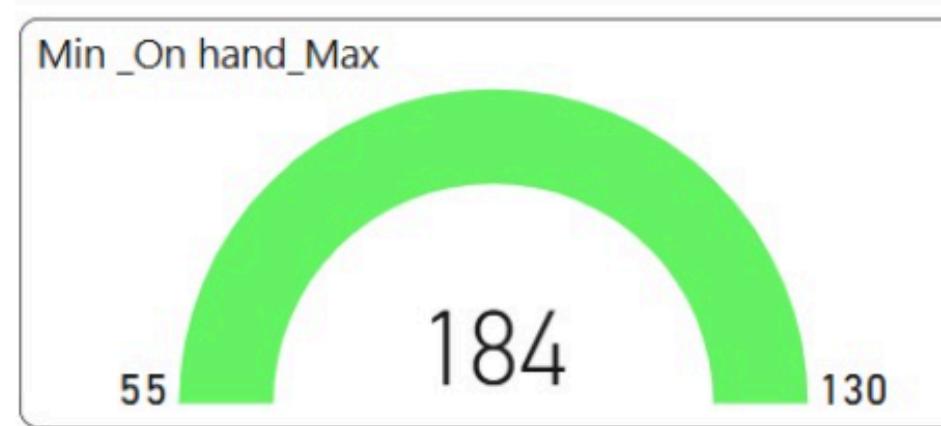
Transform - תיקון,
קידוד וביצוע ולידציה על
הנתוניים



Load - הנתוניים המוכנים
עליהם ל'מחסן נתונים'



בעיות במצב הקיום-דגימות



ItemCode

601-0017639
601-0023102
601-0026485
601-0030196
601-0039493
601-0040705
601-0040706
601-0041355
601-0046349

סיום



דשبورד ו-DI



חיציות



BI



כליים לפיתוח-AI+ML



מטרות הפרויקט



תיאור המצב הקיימ

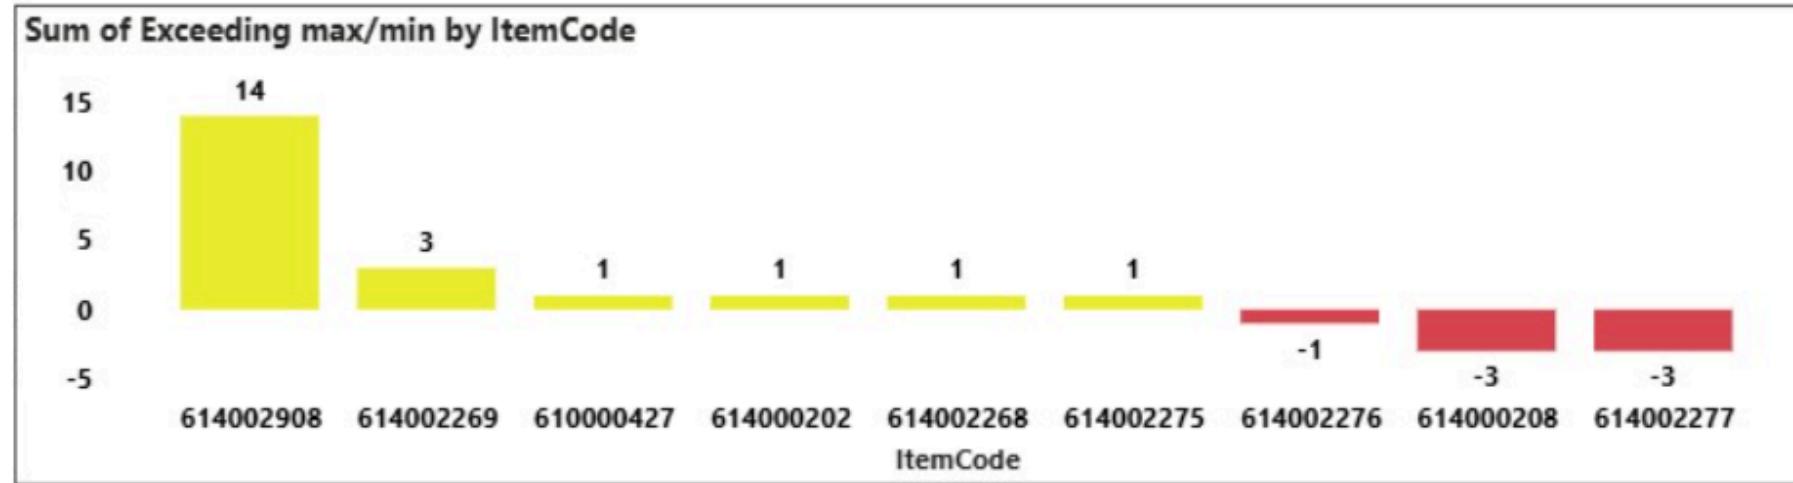


רקע

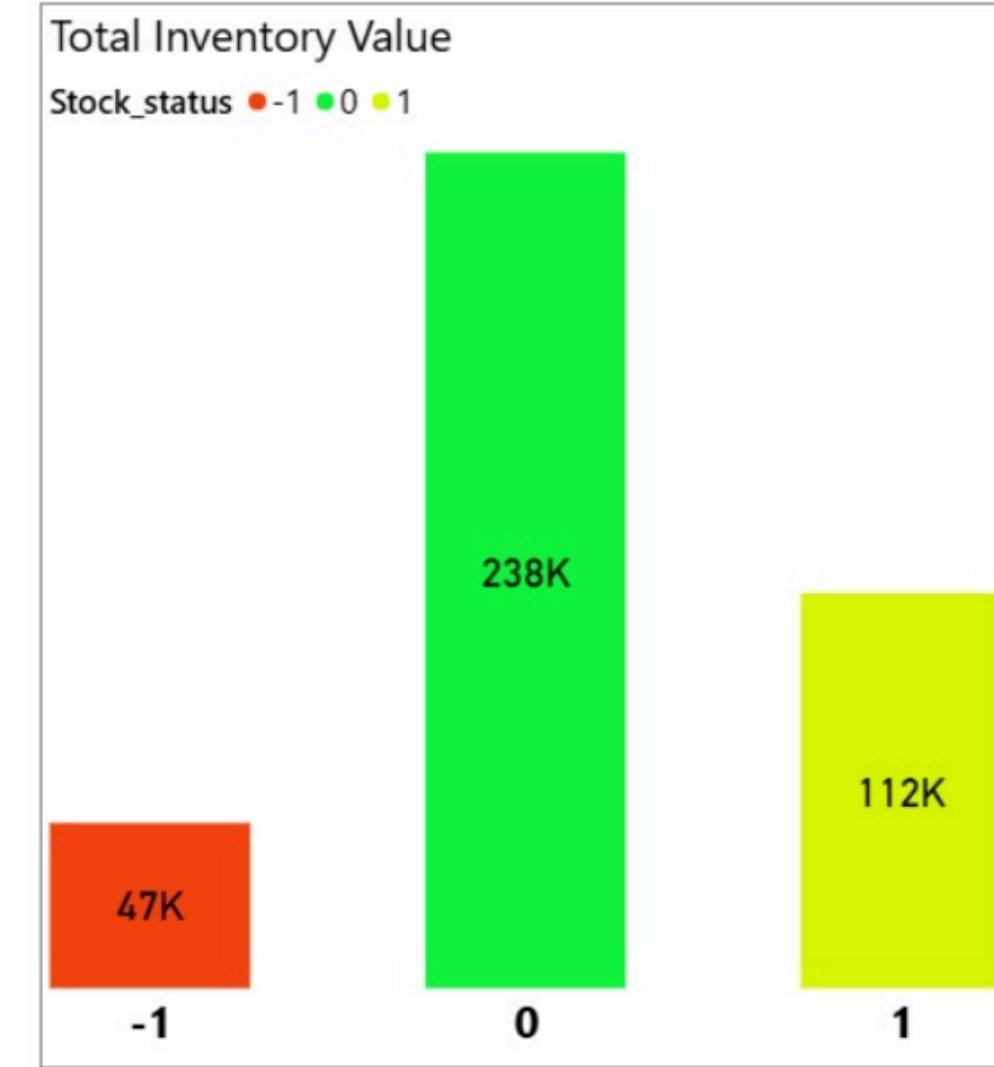


דשborod - חקר מצב קיימ

ItemCode	OnHand	MaxLevel	MinLevel	Price unit	Sum of Exceeding max/min
614002908	16.00	2	1	46.19	14.00
614002269	7.00	4	2	1,471.33	3.00
610000427	5.00	4	2	3,120.09	1.00
614000202	31.00	30	15	352.19	1.00
614002268	4.00	3	1	2,151.04	1.00
614002275	4.00	3	2	814.78	1.00
614002276	1.00	3	2	815.00	-1.00
614000208	1.00	8	4	422.04	-3.00
614002277	0.00	6	3	814.74	-3.00



חריגות מלאים בקטו הכספי



ערך בספי של החריגות



בחירה מודלים עונתיים:

Arima



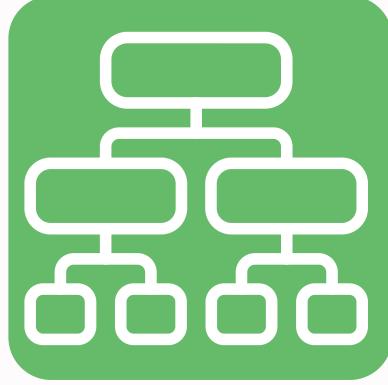
Random Forest



Porphet



Xgboost



סיום



דשبورד ו-DI



חיזיון



BI



כליים לפיתוח-AI+ML



מטרות הפרויקט



תיאור המצב הנוכחי



רקע



הצדקה ספרותית

“In summary, we can conclude that ARIMA in state-space form is a practical and efficient option for supply-chain forecasting and, indeed, for any context where the historical time series is limited to a few complete seasonal cycles.” (Ivan Svetunkov & John E. Boylan, State-space ARIMA for Supply-Chain Forecasting)

מודל ARIMA הוא מודל מעשי וטוב לחיזוי, גם כאשר יש הגבלה על סדרת הזמן.



תהליך הפיתרון

מודל ARIMA

```

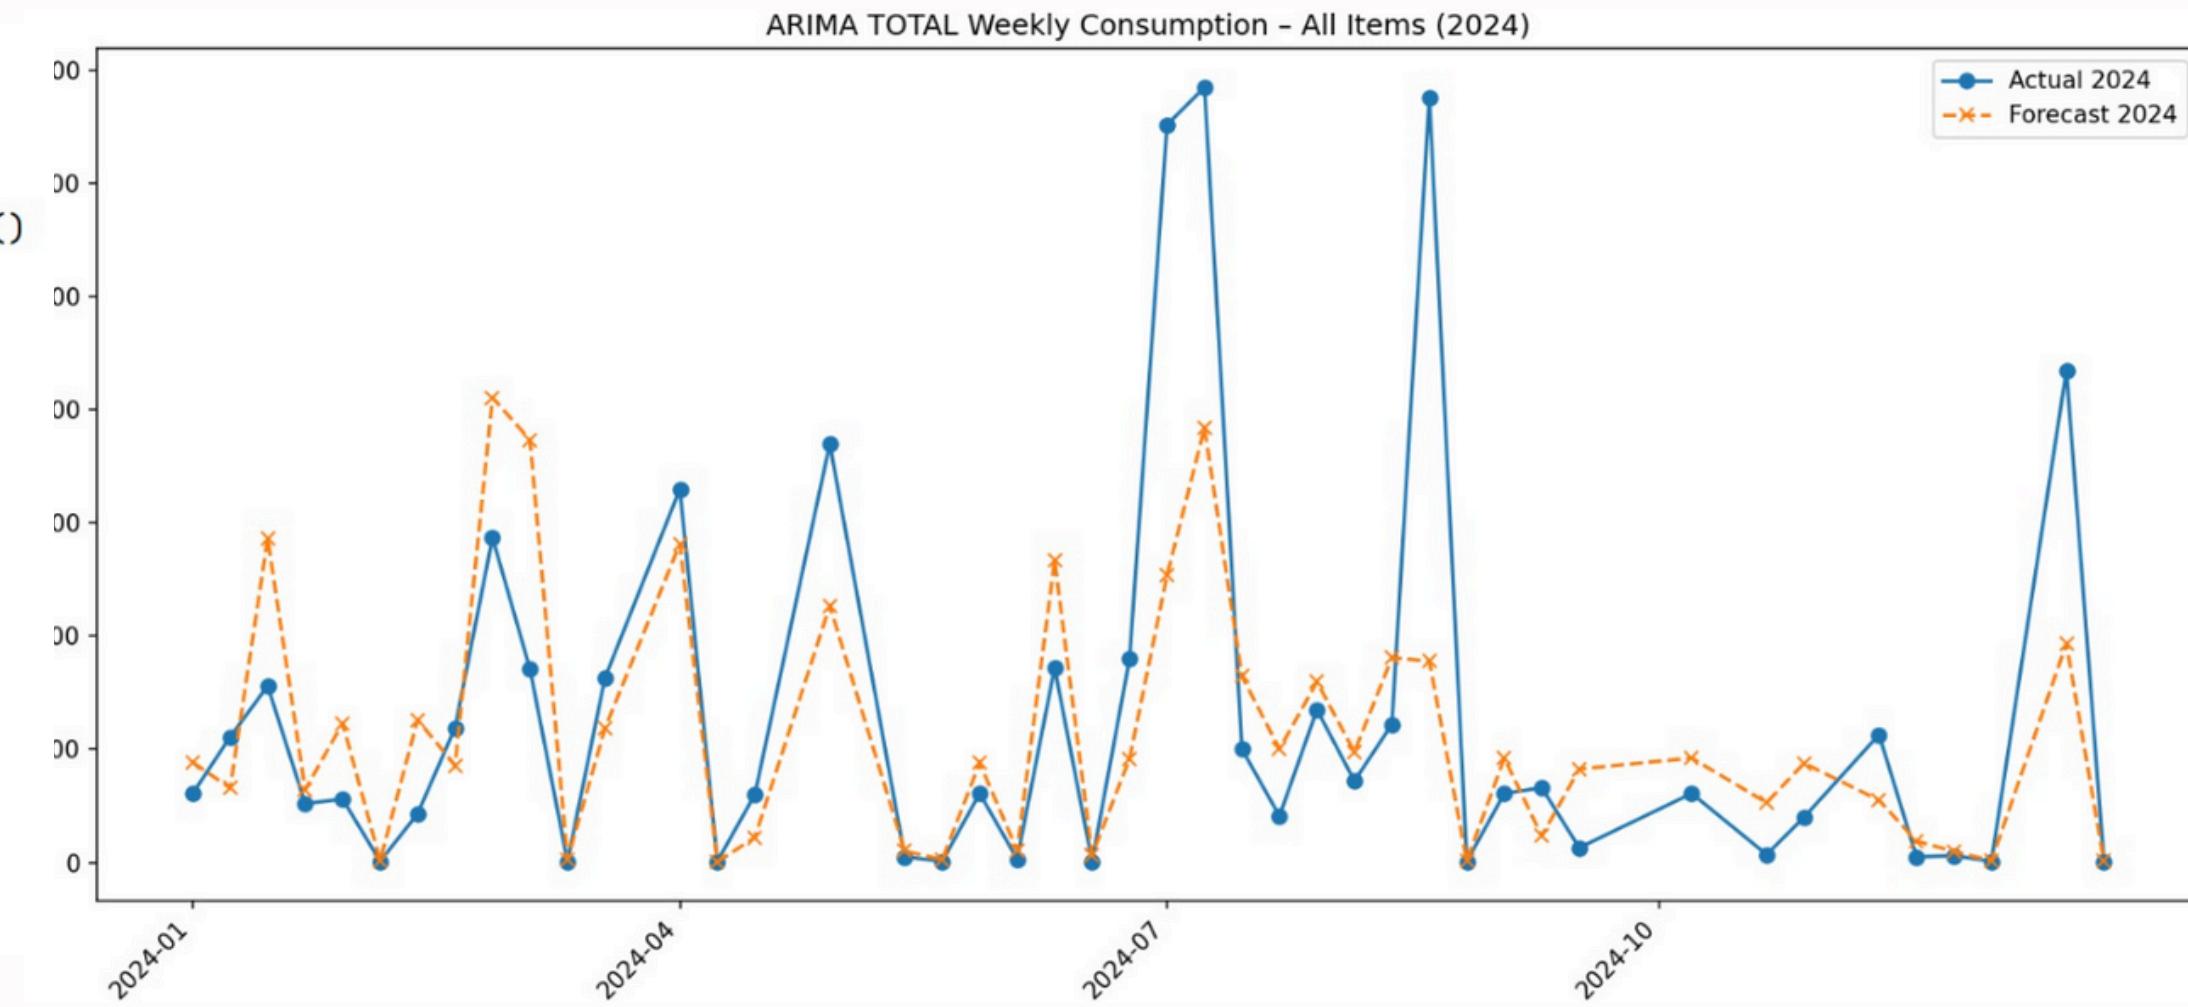
for item in item_codes:
    try:
        item_df = df[df['ItemCode'] == item].copy()
        weekly = item_df.groupby('Week')['ConsumptionQty'].sum().to_timestamp()

        train = weekly[weekly.index.year <= 2023]
        test = weekly[weekly.index.year == 2024]

        adf_result = adfuller(train)
        d_value = 0 if adf_result[1] < 0.05 else 1

        model = ARIMA(train, order=(1, d_value, 1))
        model_fit = model.fit()

        forecast = model_fit.forecast(steps=len(test))
        forecast.index = test.index
    
```



סיום



דשborad - DI



חיזויים



BI



כליים לפיתרון-AI+ML



מטרות הפרויקט



תיאור המצב הנוכחי

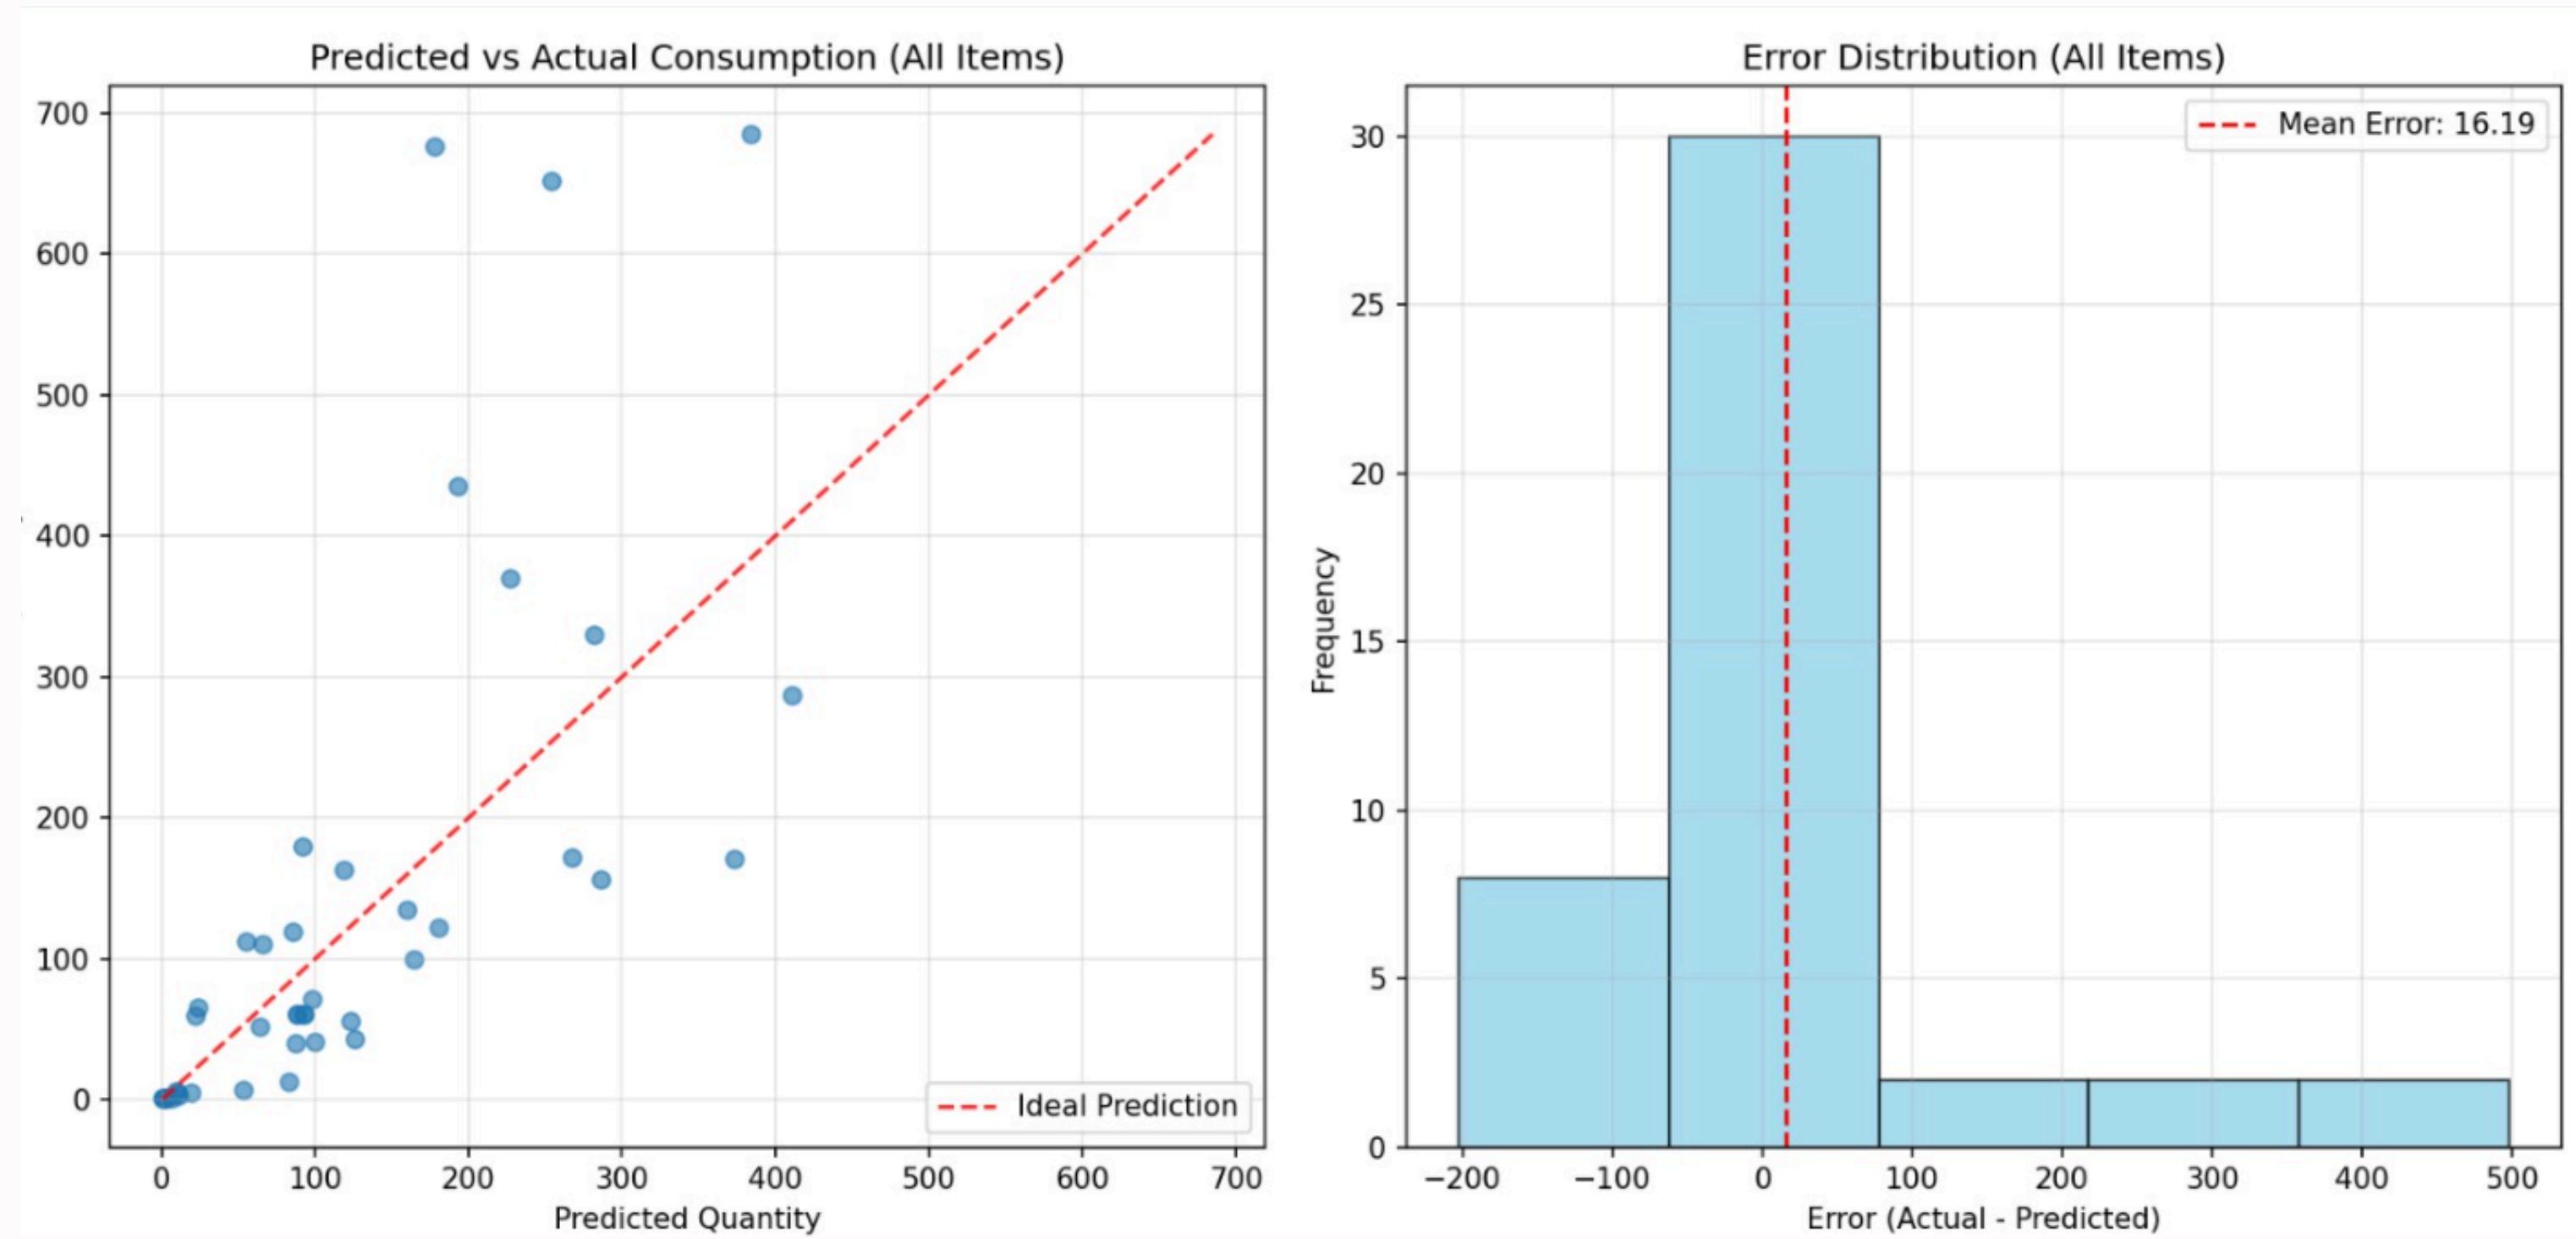


רקע



חיזויים

מודל ARIMA



Random Forest מודל

```
features = ['PRICE', 'LT_Days', 'InventoryBalance', 'ConsumptionYear', 'ConsumptionWeek', 'I
X = grouped[features]
y = grouped['ConsumptionQty']

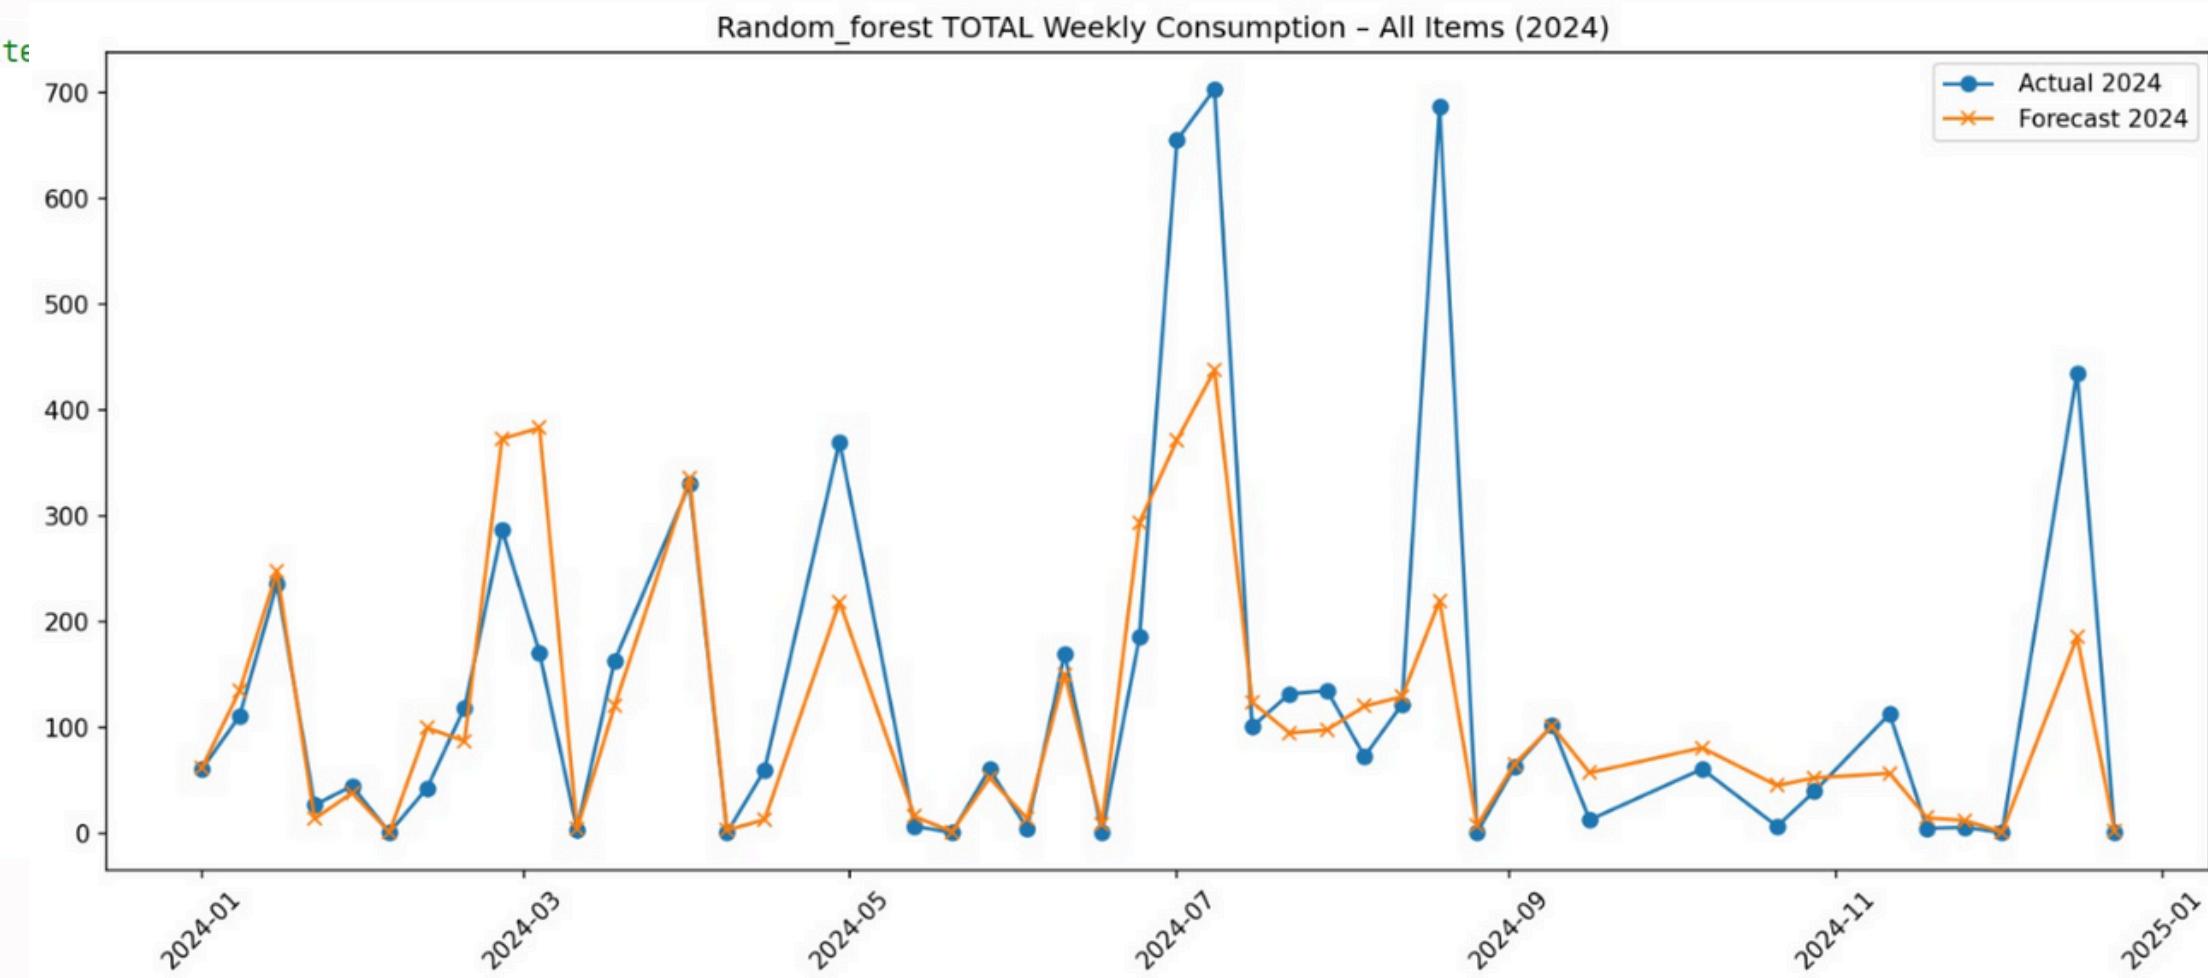
train_data = grouped[grouped['ConsumptionYear'] <= 2023]
test_data = grouped[grouped['ConsumptionYear'] == 2024]

X_train = train_data[features]
y_train = train_data['ConsumptionQty']

model = RandomForestRegressor(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

item_codes = grouped['ItemCode'].unique()

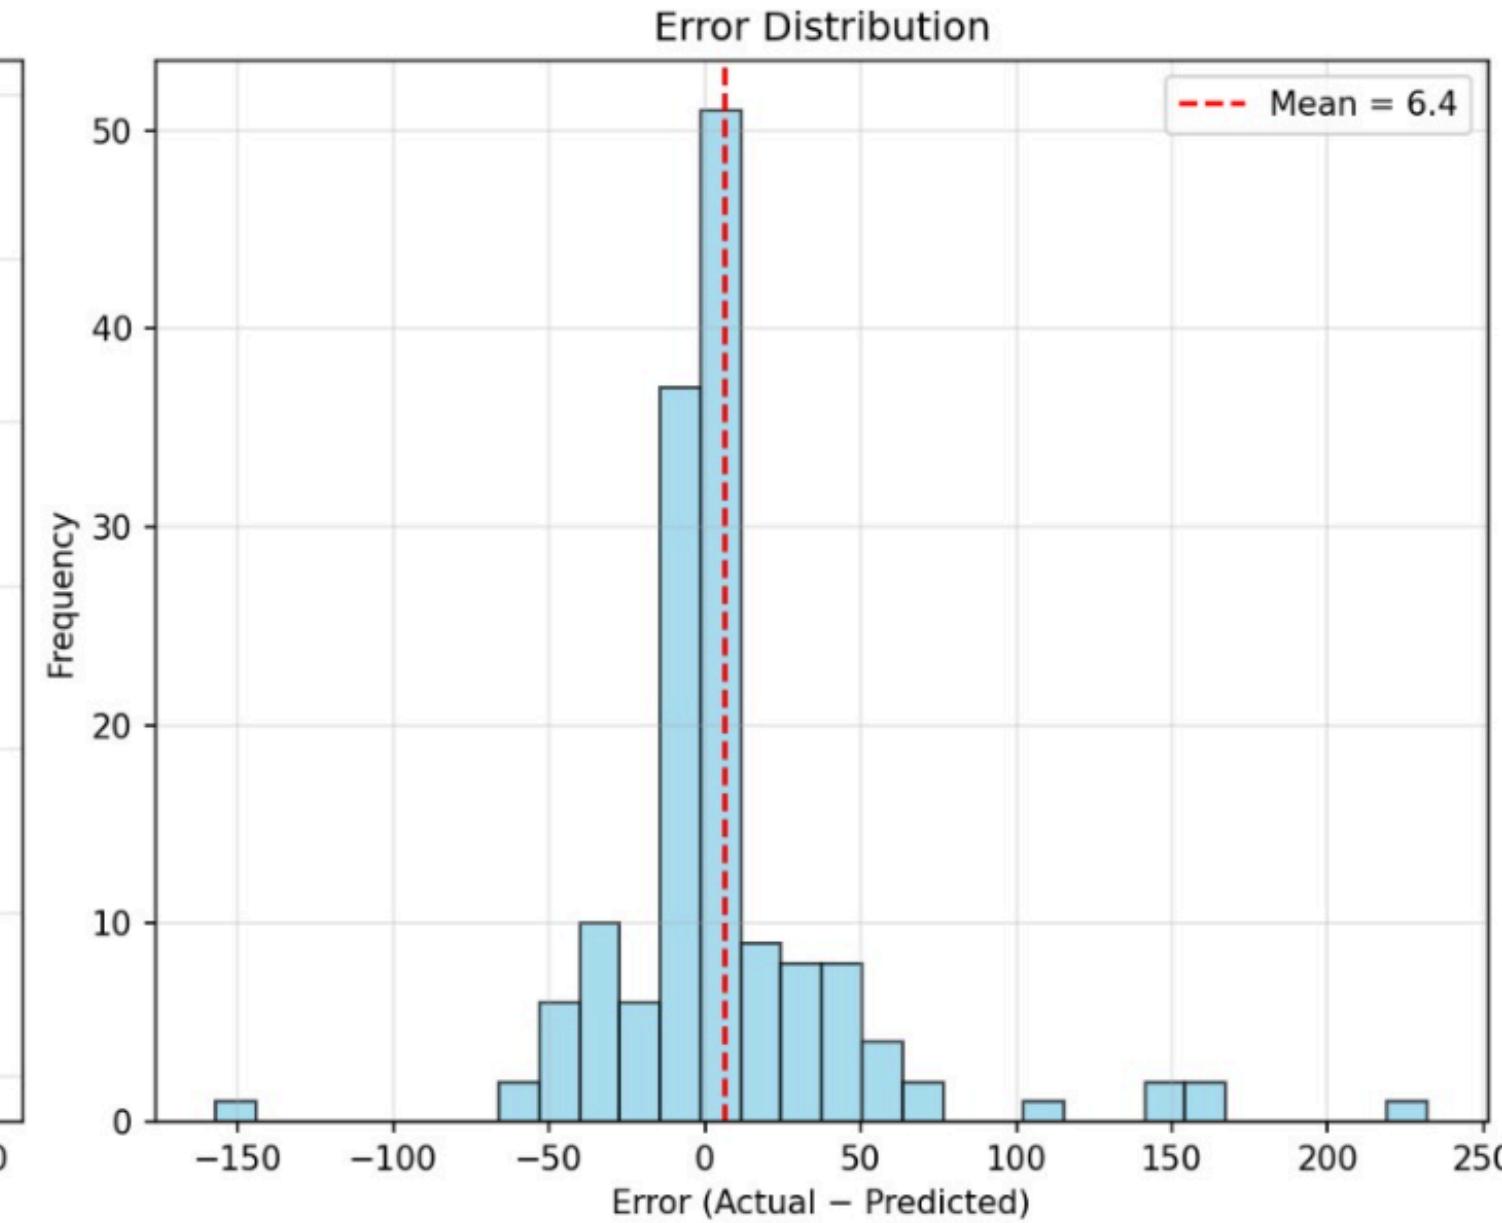
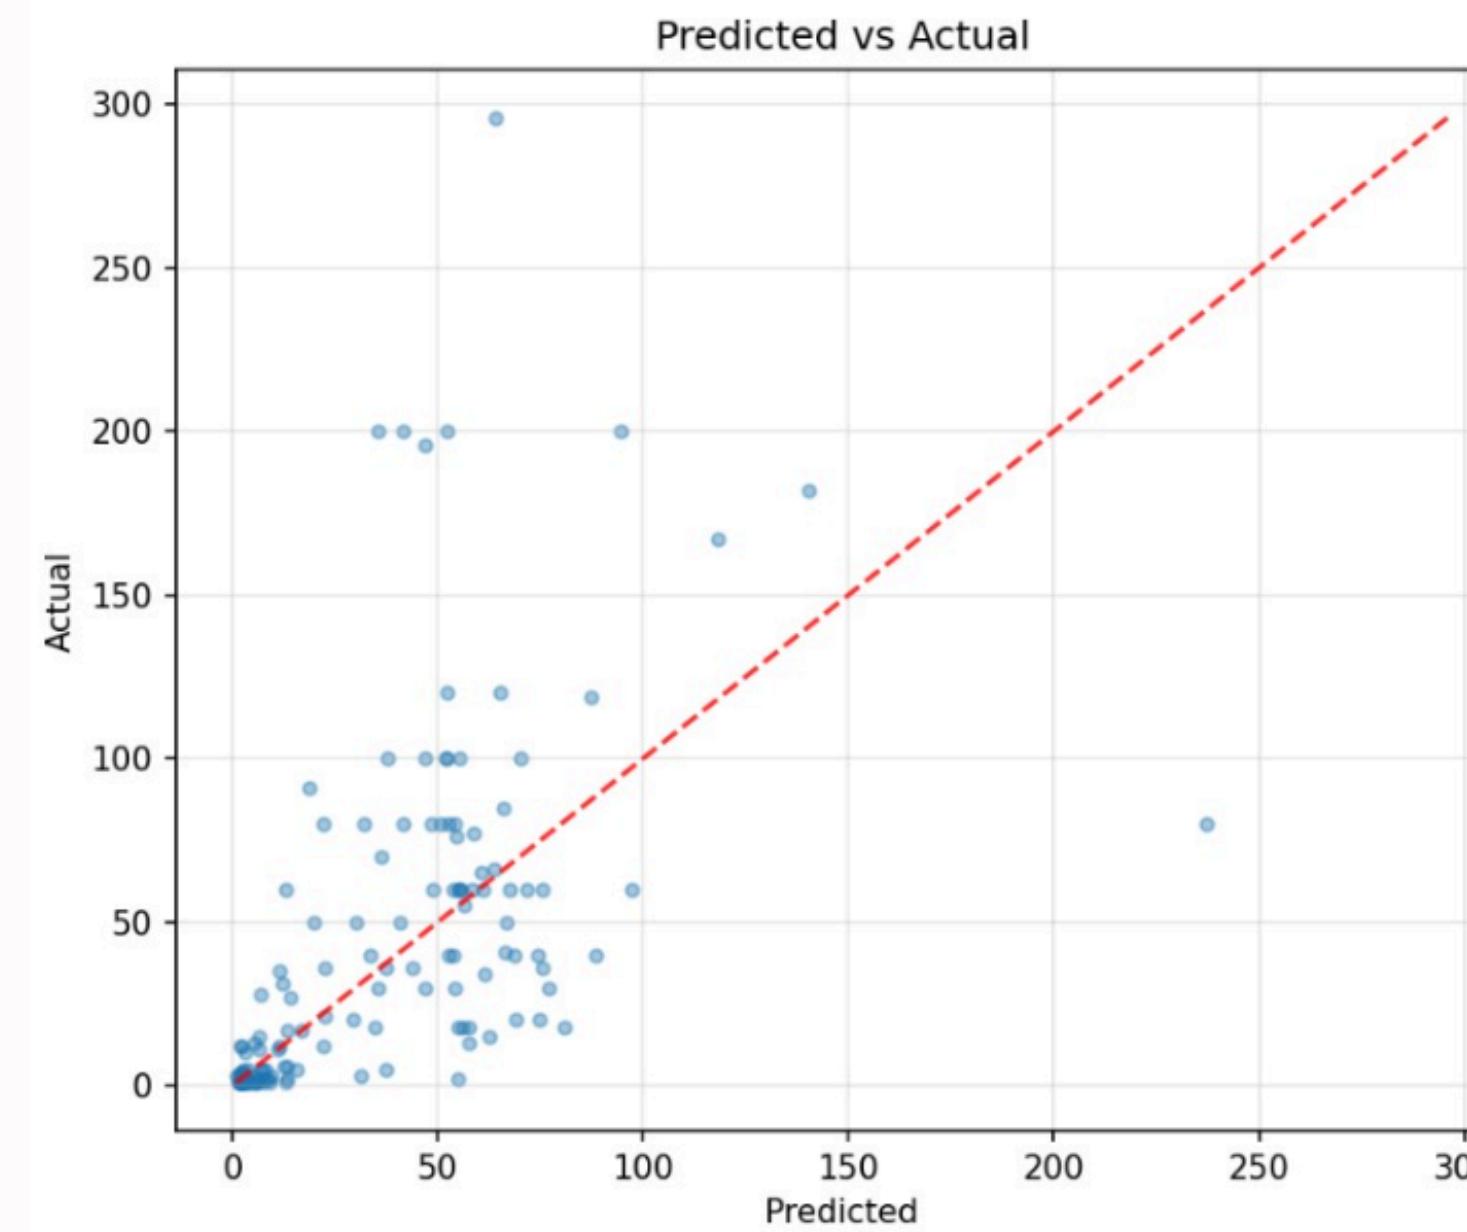
last_date_training = df[df['ConsumptionYear'] < 2024]['ConsumptionDate'].max()
future_data = []
```



מודל Random Forest

פיזור השגיאות

Random_Forest Global Forecast Diagnostics (2024)



MAE: 5.9
RMSE: 7.97
 R^2 : 0.68

סיום



דשبورד ו-DI



חיזיון



BI



כליים לפיתוח-AI+ML



מטרות הפרויקט



תיאור המצב הנוכחי



רקע



הצדקה ספרותית

“Since it performs parallelization and decentralization, it has an extremely fast learning speed and high prediction accuracy compared to the existing tree-based algorithms.” (Yechan Han, Jaeyun Kim & David Enke, “A machine learning trading system for the stock market based on N-period Min-Max labeling using XGBoost”)

מודל ה-XGBoost הוא מודל מהיר, נוח עם אחזוי דיווק גבוהים, גם בהשוואה לאלגוריתמים עם עצי החלטה אחרים.



מודל XGBOOST

```

train_df = grouped[grouped["ConsumptionYear"] < 2024]
test_df = grouped[grouped["ConsumptionYear"] == 2024]

features = ["PRICE", "LT_Days", "InventoryBalance",
            "ConsumptionYear", "ConsumptionWeek", "ItemCode_encoded"]

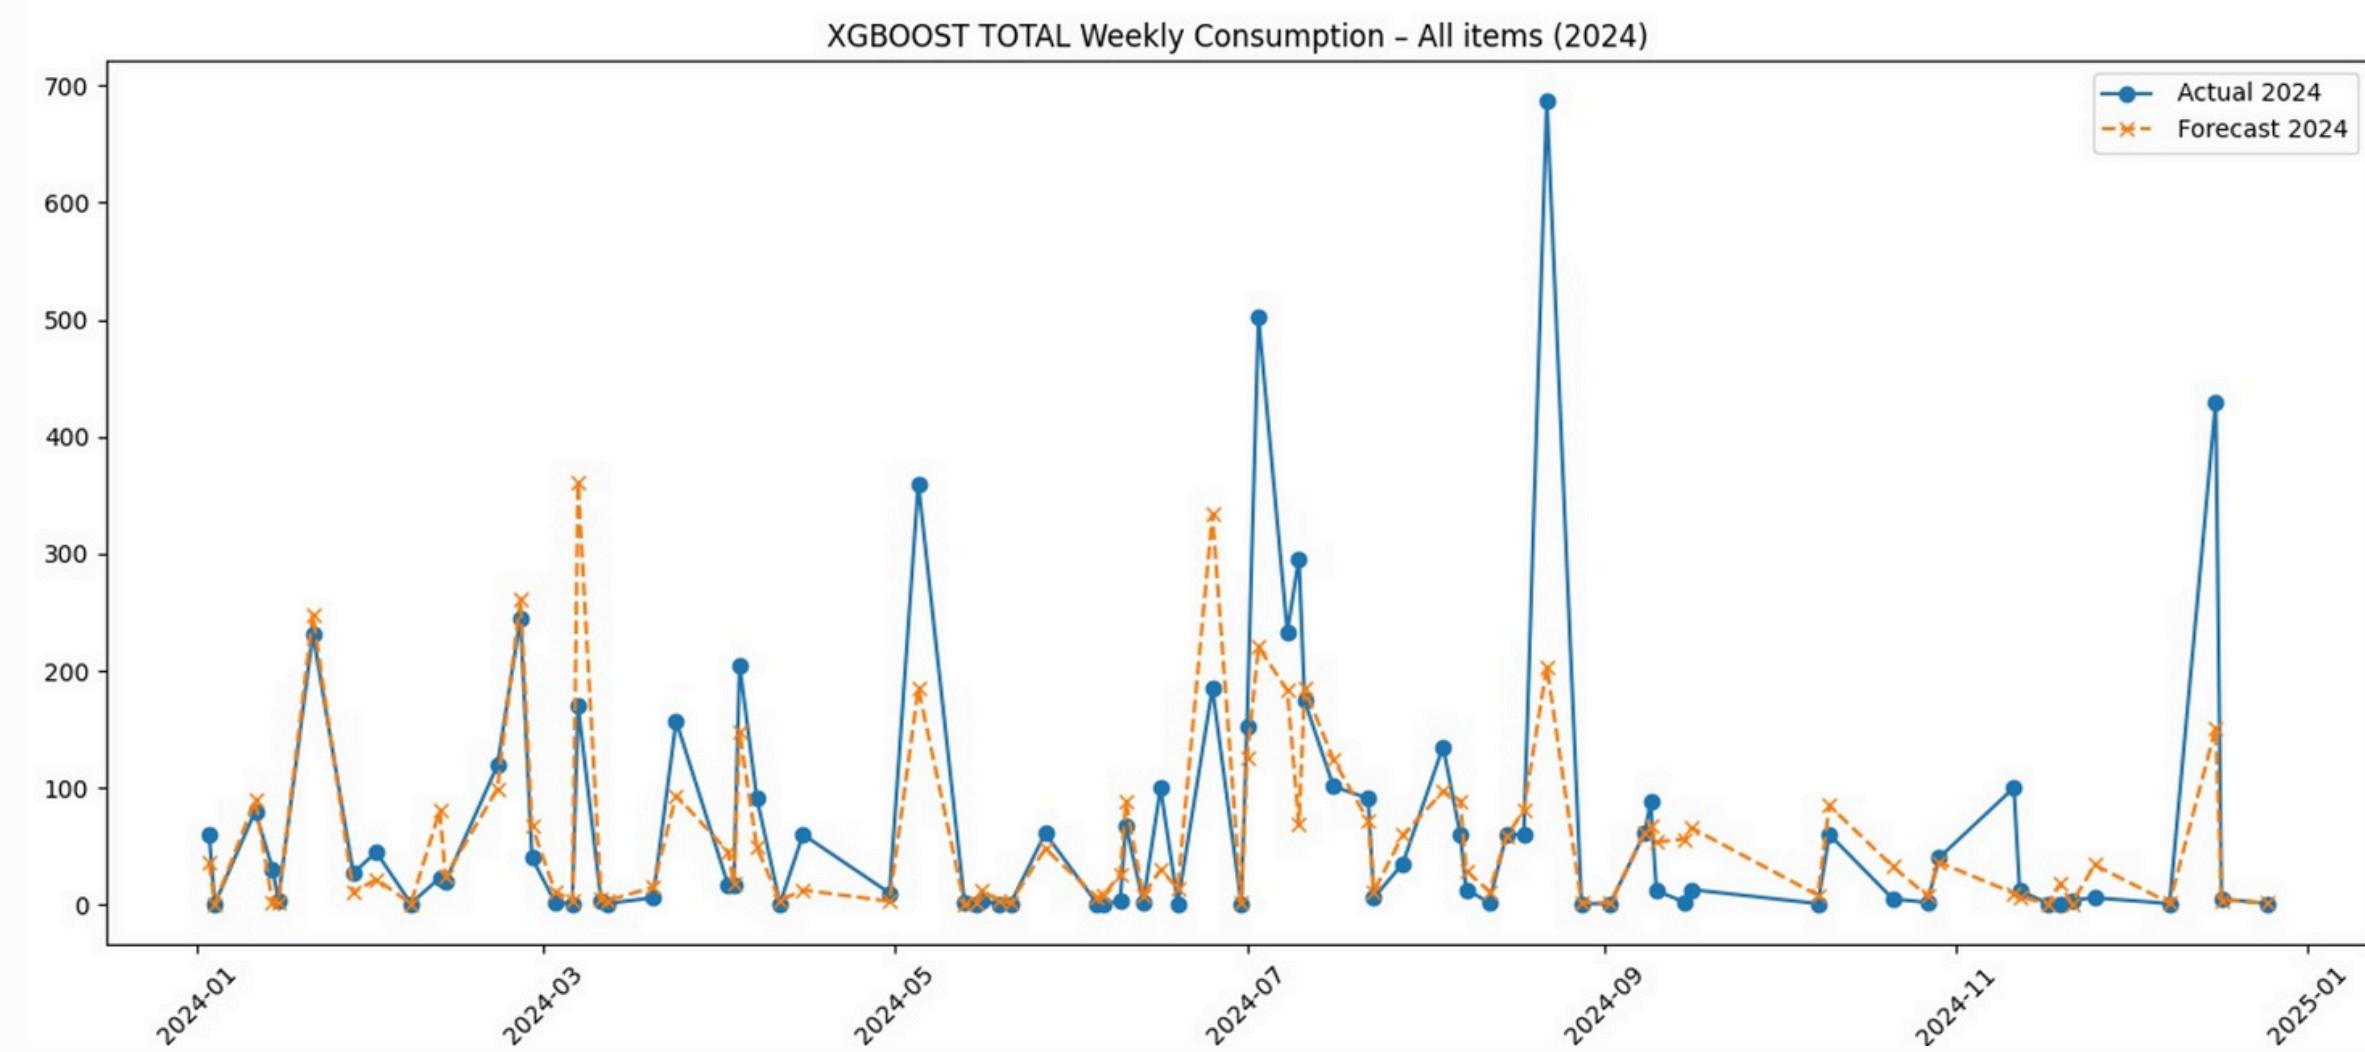
X_train, y_train = train_df[features], train_df["ConsumptionQty"]
X_test, y_test = test_df[features], test_df["ConsumptionQty"]

model = XGBRegressor(
    objective="reg:squarederror",
    n_estimators=300, learning_rate=0.1,
    max_depth=6, subsample=0.8, colsample_bytree=0.8,
    random_state=42, n_jobs=-1)

model.fit(X_train, y_train)

test_df["PredictedQty"] = model.predict(X_test)

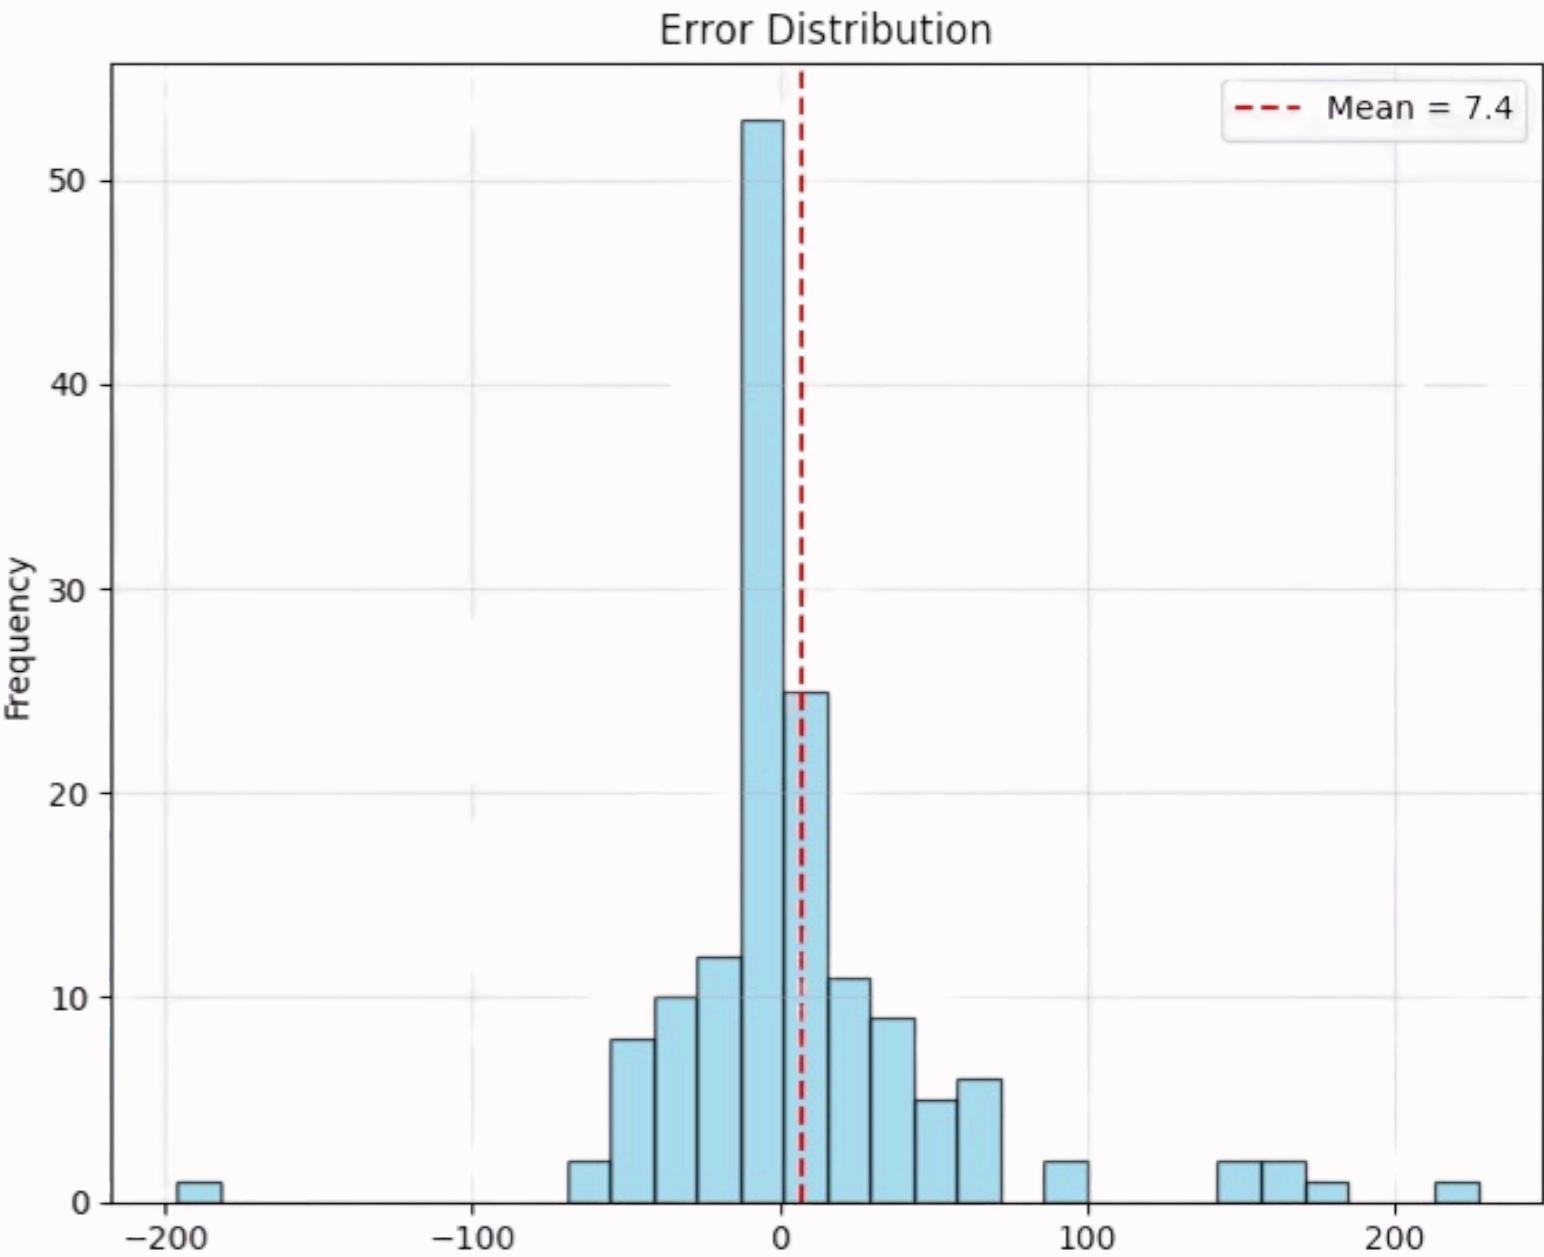
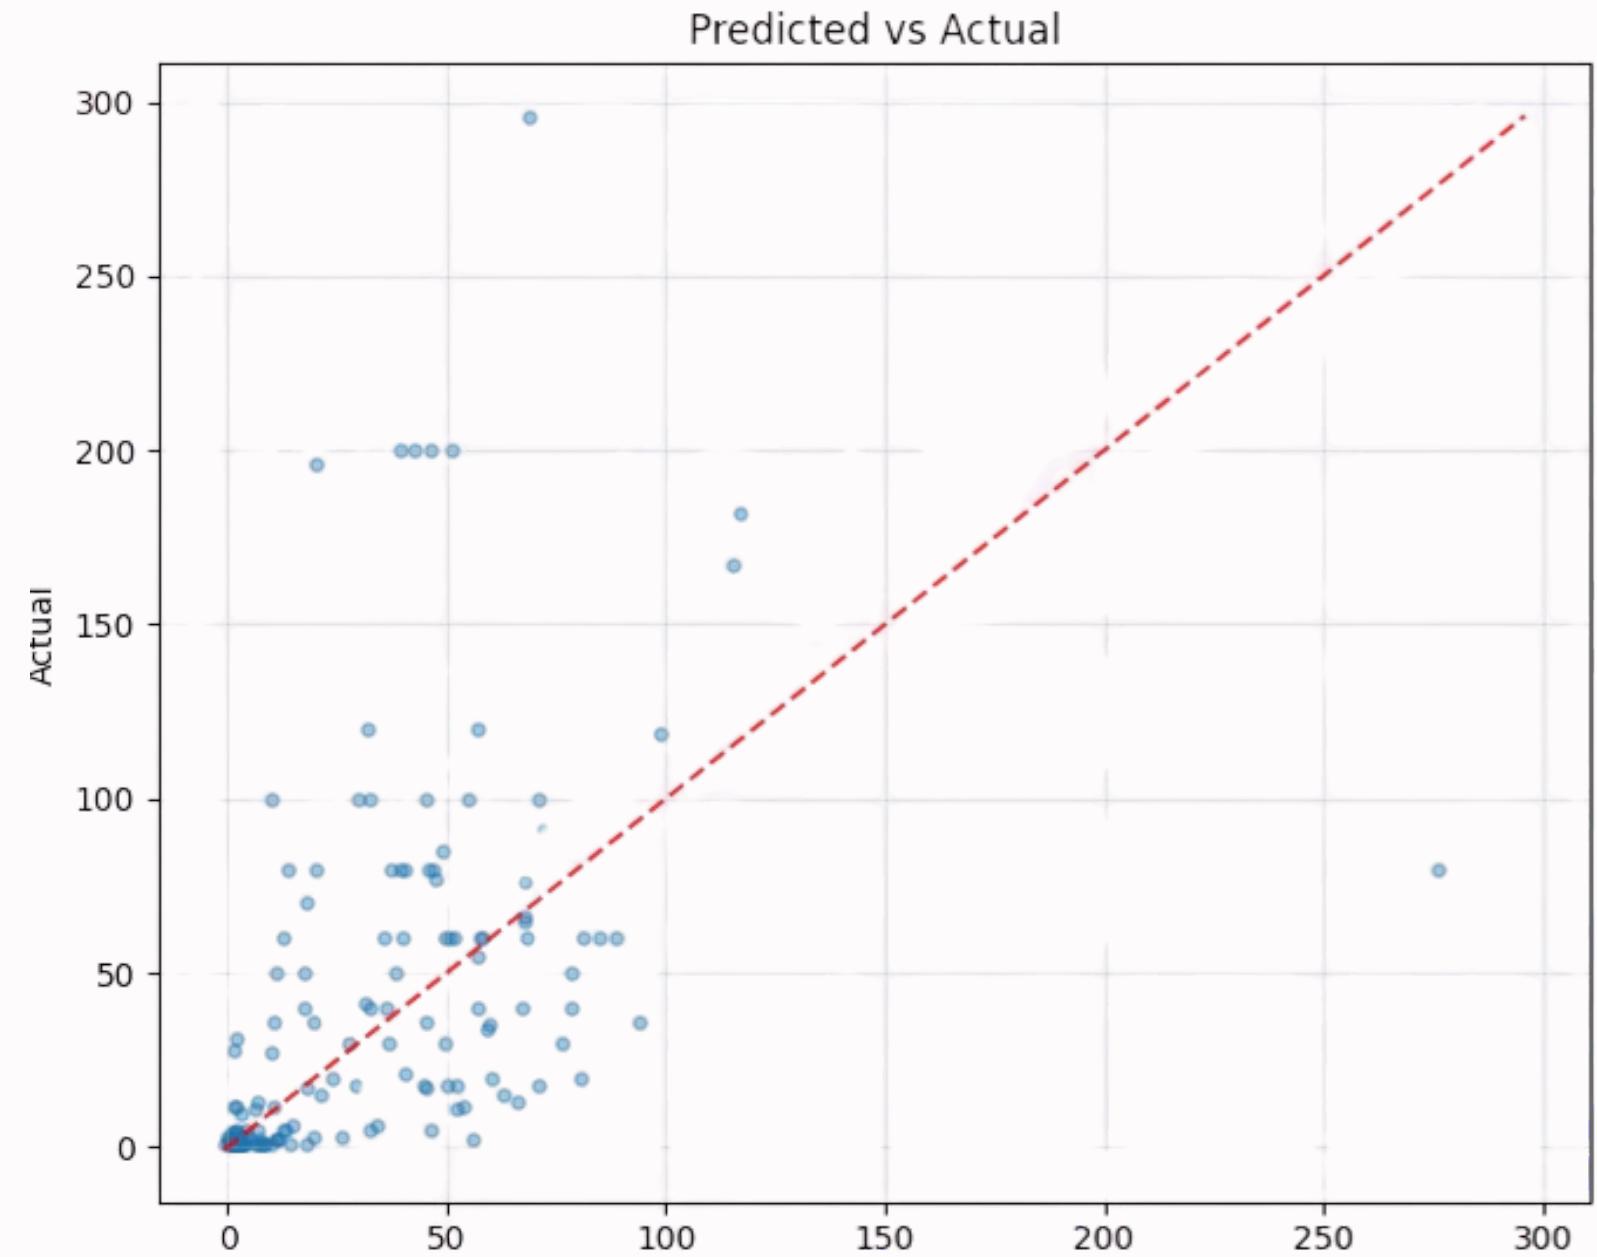
```



XGBOOST

פיזור השגיאות

XGBOOST Global Forecast Diagnostics (2024)



MAE: 7.4
RMSE: 9.94
 R^2 : 0.43

סיעום



דשبورד - DI



חיציותם



BI



כלים לפיתוח-AI+ML



מטרות הפרויקט



תיאור המצב הנוכחי

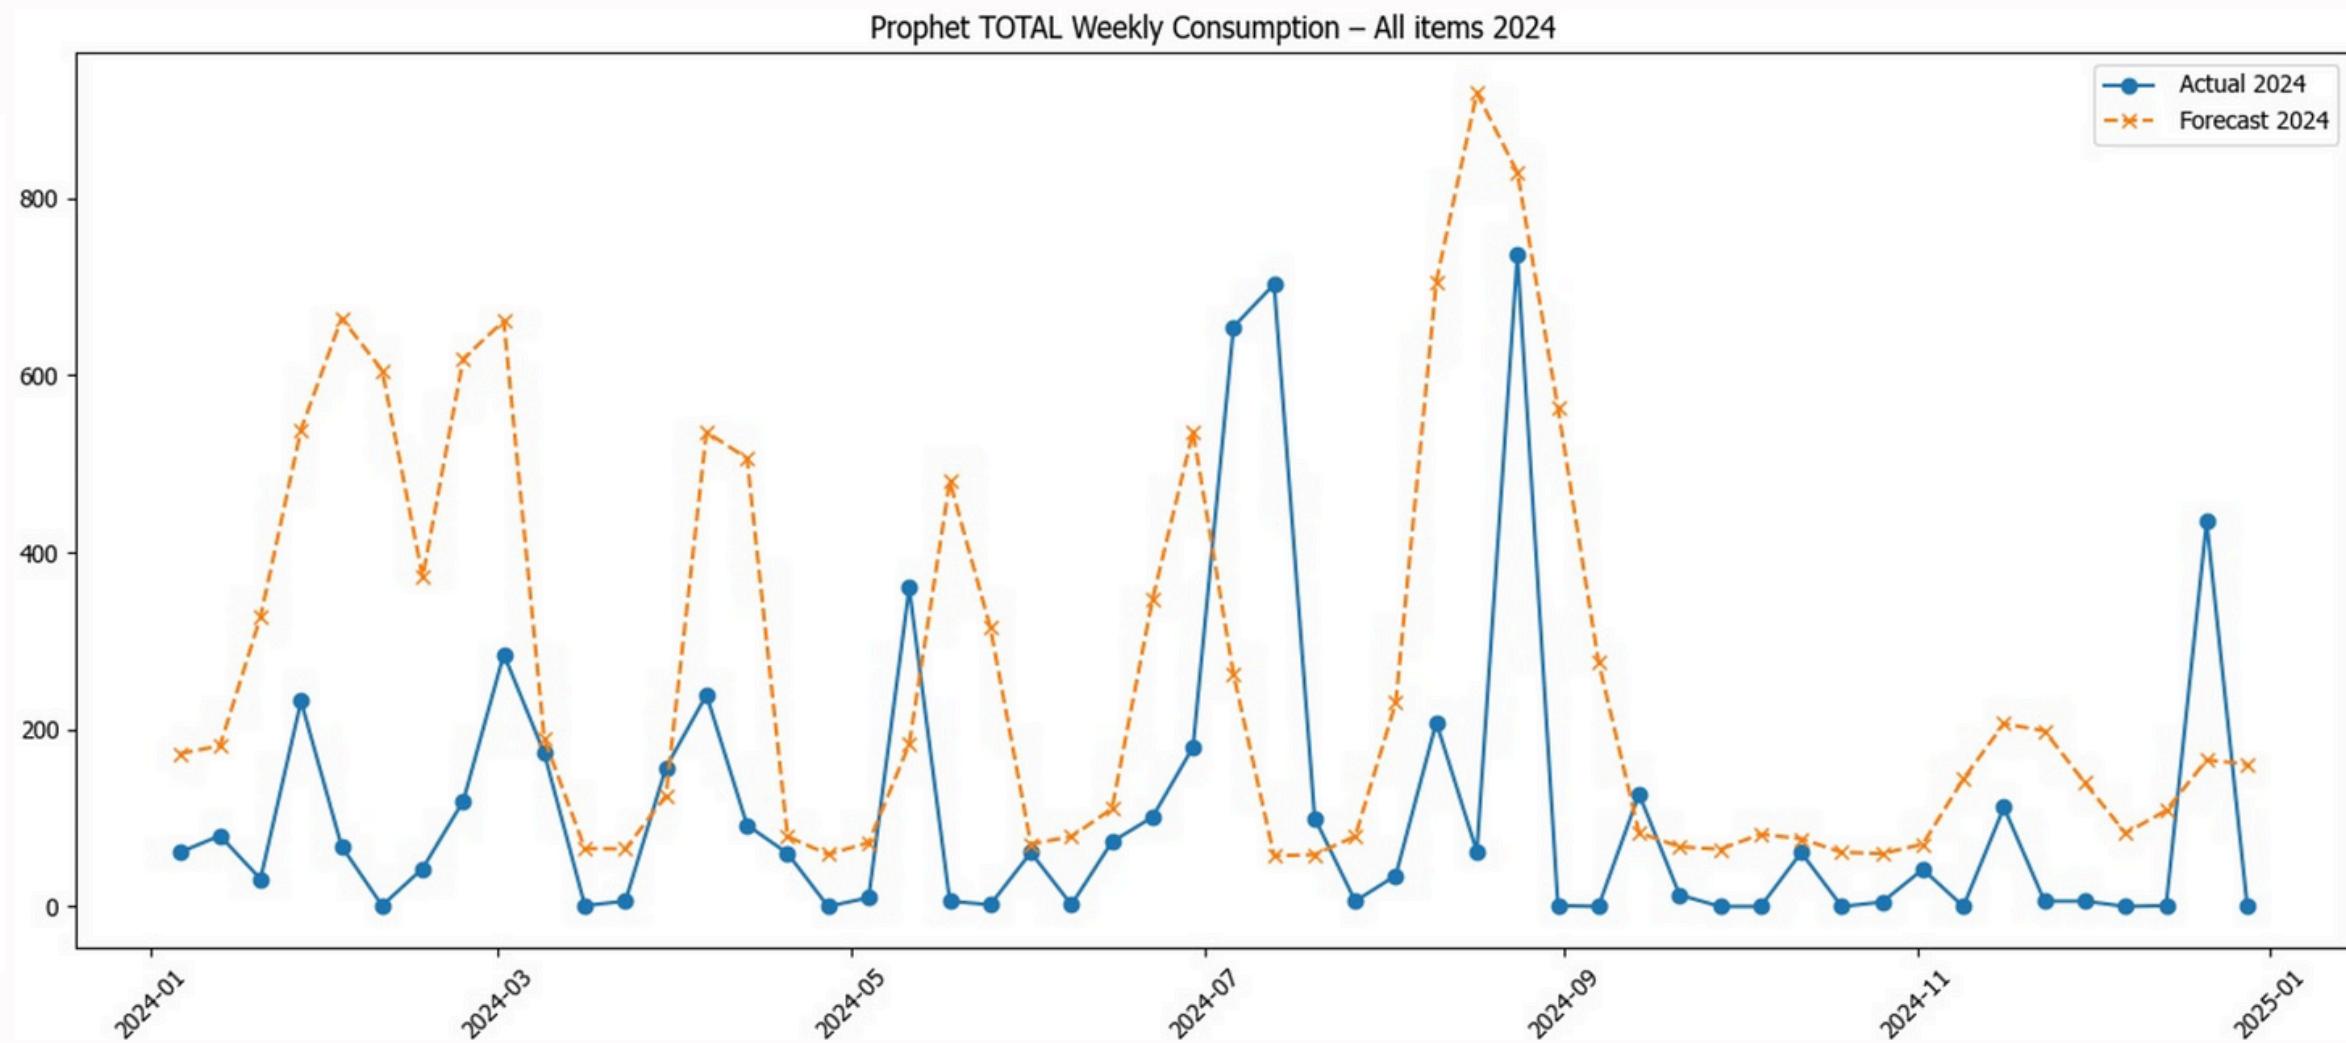


רקע



מודל prophet

```
# --- 3. Train the Prophet model -----
m = Prophet(
    yearly_seasonality=True,
    weekly_seasonality=True,
    daily_seasonality=False
)
m.fit(tr)
# --- 4. Build a 52-week future dataframe (Saturdays of the test year) -
first_sat = pd.Timestamp(f"{self.test_year}-01-01")
first_sat += pd.DateOffset(days=(5 - first_sat.weekday()) % 7) # next Saturday
future_dates = pd.date_range(first_sat, periods=52, freq="W-SAT")
future = pd.DataFrame({"ds": future_dates, "floor": 0})
# --- 5. Predict and clip negative values -----
fcst = (
    m.predict(future)[["ds", "yhat"]]
    .rename(columns={"ds": "Date", "yhat": "Forecast"})
)
fcst["Forecast"] = fcst["Forecast"].clip(lower=0)
```



סיום



แดשborad + DI



חיזויים



BI



כלים לפיתוח-AI+ML



מטרות הפרויקט



תיאור המצב הנוכחי



רקע

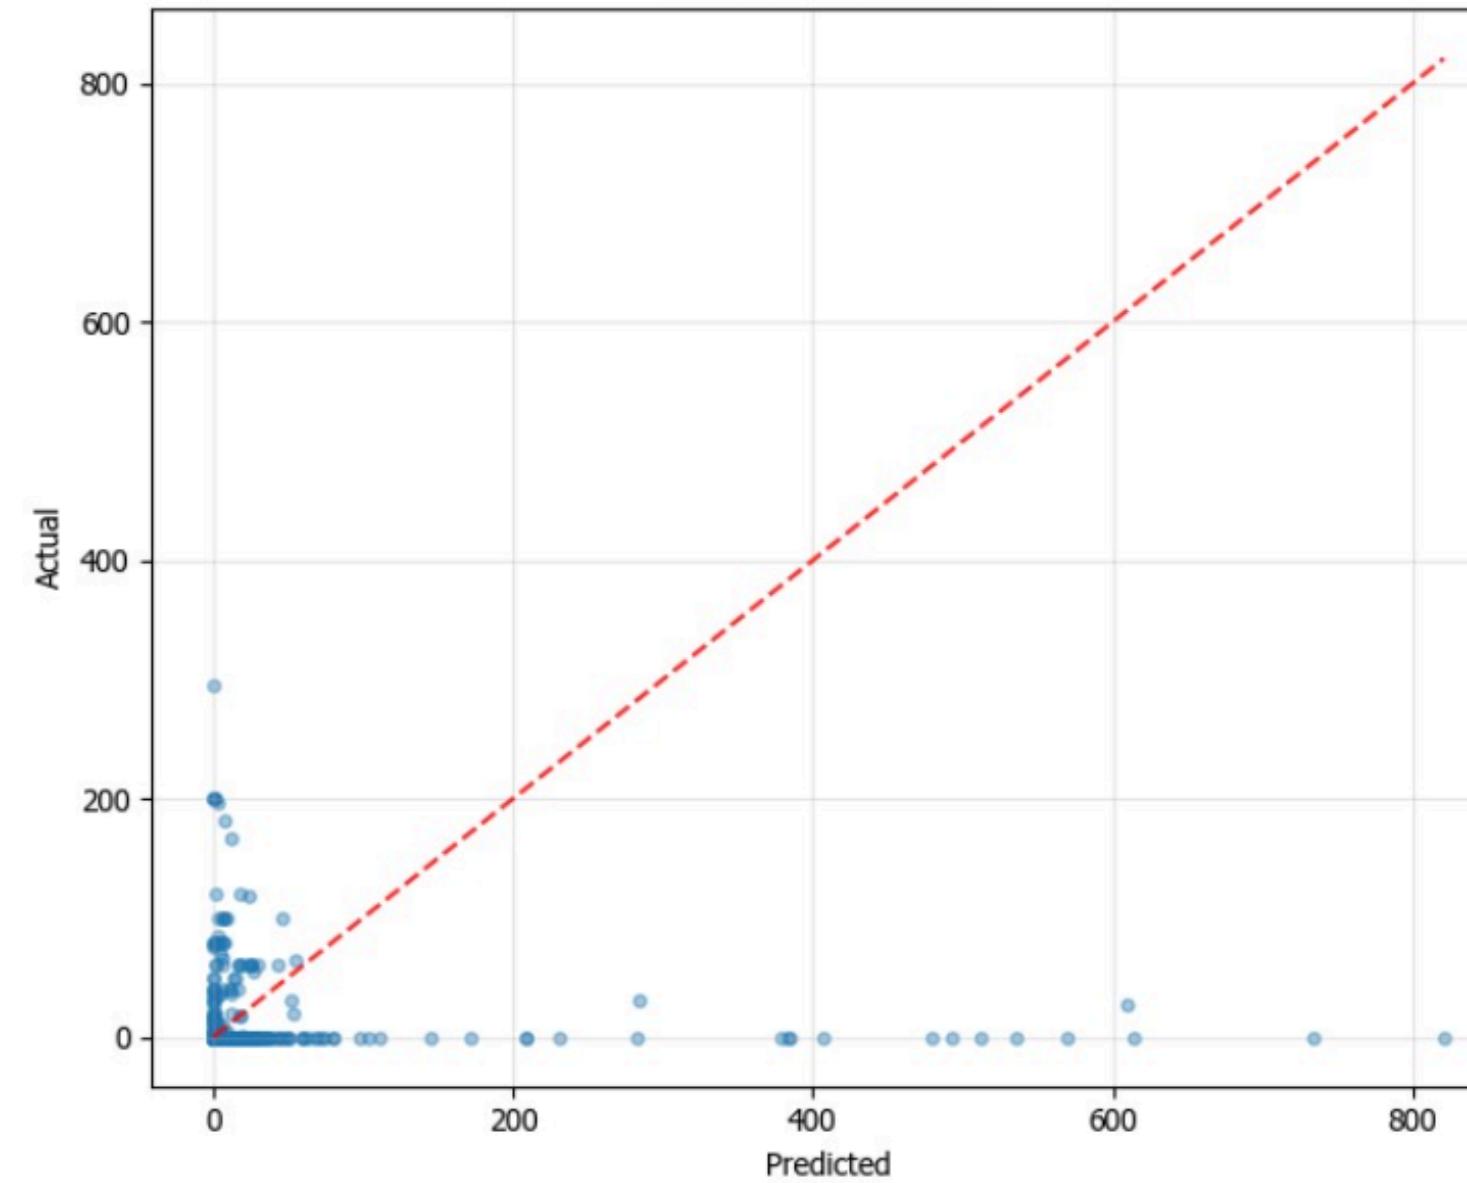


מודל prophet

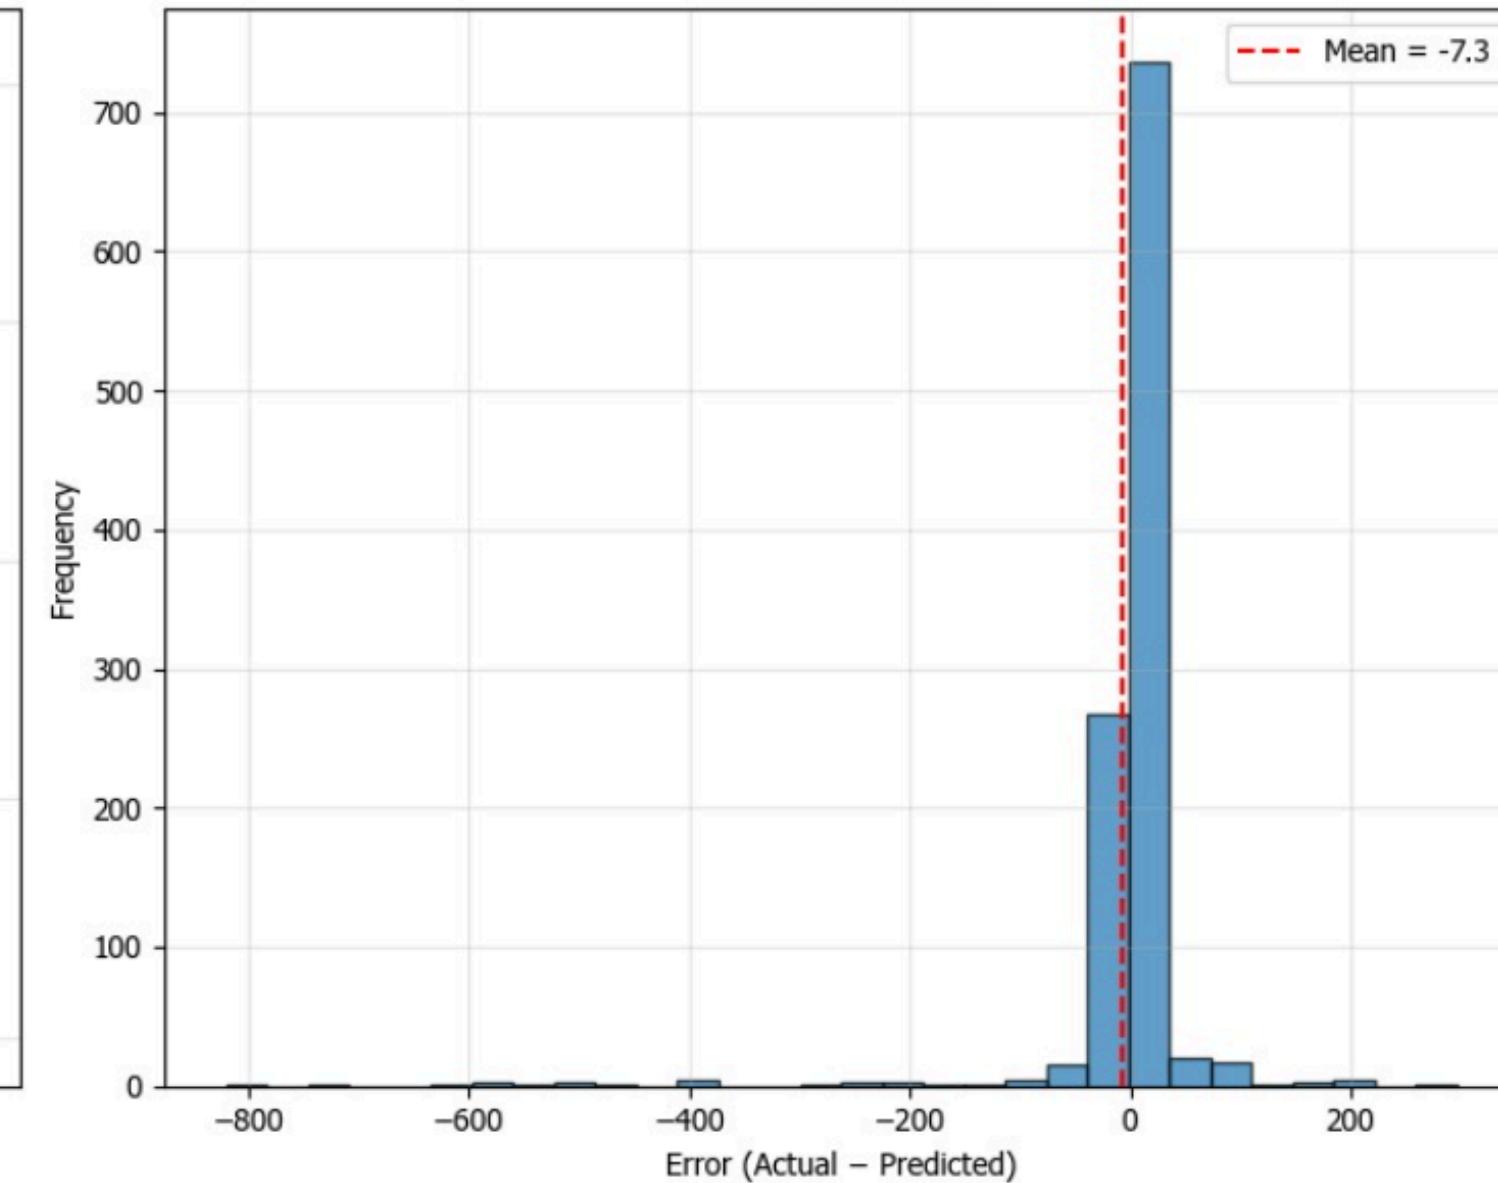
פיזור השגיאות

Prophet Global Forecast Diagnostics (2024)

Predicted vs Actual



Error Distribution



MAE: 16.37

RMSE: 67.02

R²: 0.3

סיום



דשبورד ו-DI



חיזיון



BI



כליים לפיתוח-AI+ML



מטרות הפרויקט

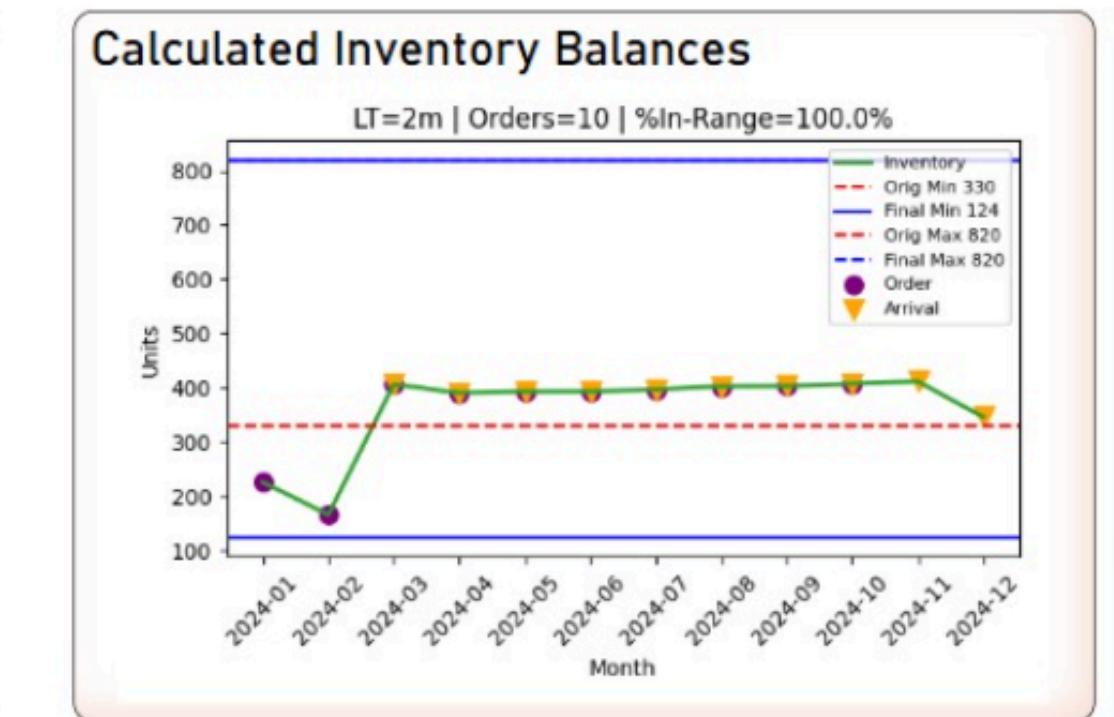
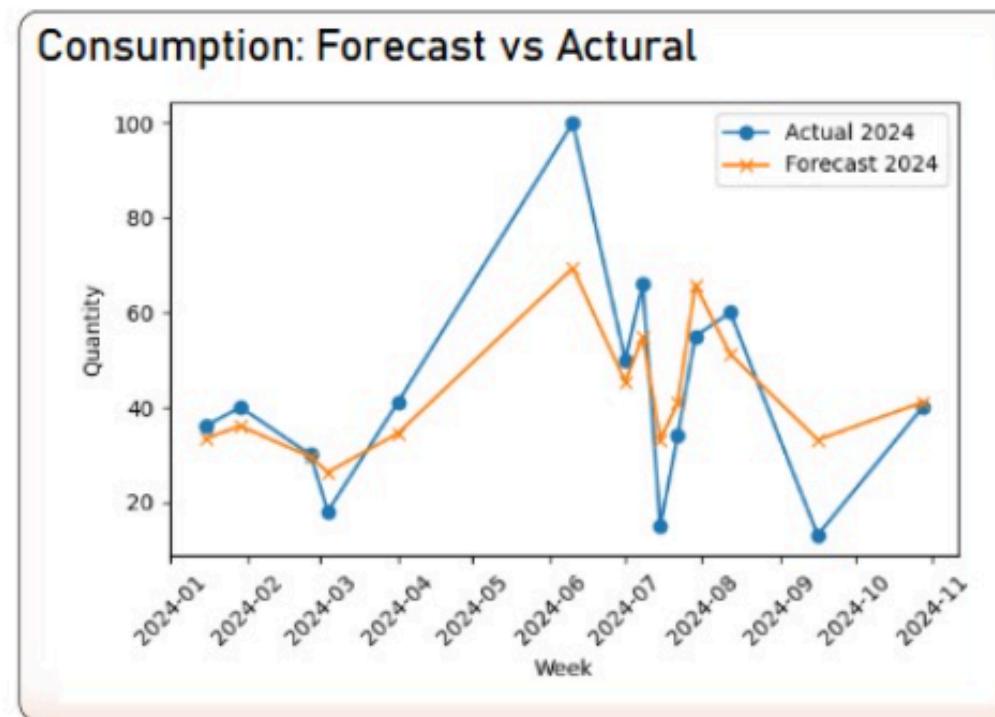
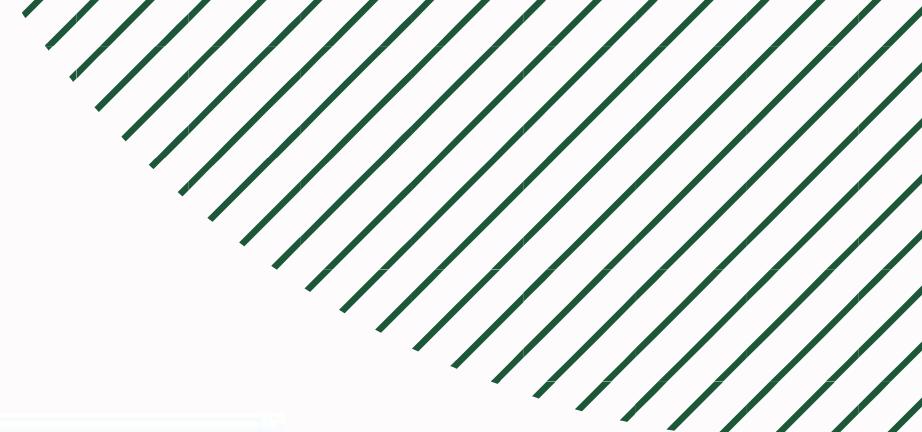


תיאור המצב הנוכחי



רקע





ItemCode

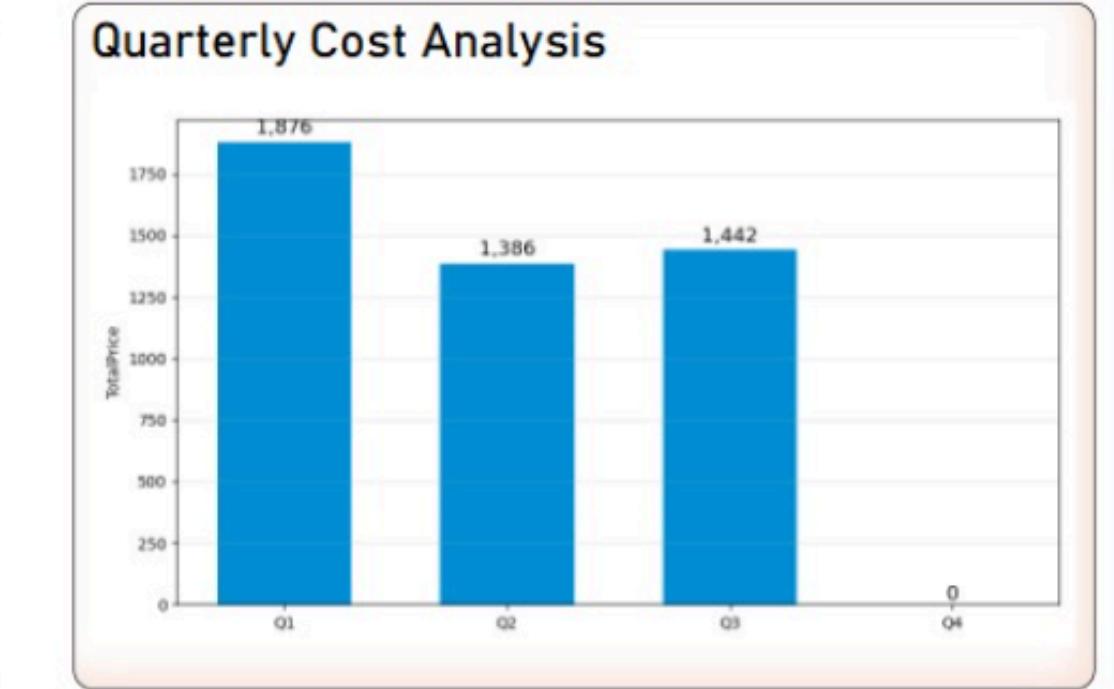
601-0015663

601-0020158

601-0021438

Purchase Orders Overview

SKU	OrderDate	ArrivalDate	Quantity	PRICE	TotalPrice
601-0020158	2024-01-01	2024-03-01	160	7	1120
601-0020158	2024-02-01	2024-04-01	44	7	308
601-0020158	2024-03-01	2024-05-01	64	7	448
601-0020158	2024-04-01	2024-06-01	63	7	441
601-0020158	2024-05-01	2024-07-01	66	7	462
601-0020158	2024-06-01	2024-08-01	69	7	483
601-0020158	2024-07-01	2024-09-01	66	7	462
601-0020158	2024-08-01	2024-10-01	70	7	490
601-0020158	2024-09-01	2024-11-01	70	7	490



סיום



דשبورד DI



חיצויים



BI



כליים לפיתוח-AI+ML



מטרות הפרויקט



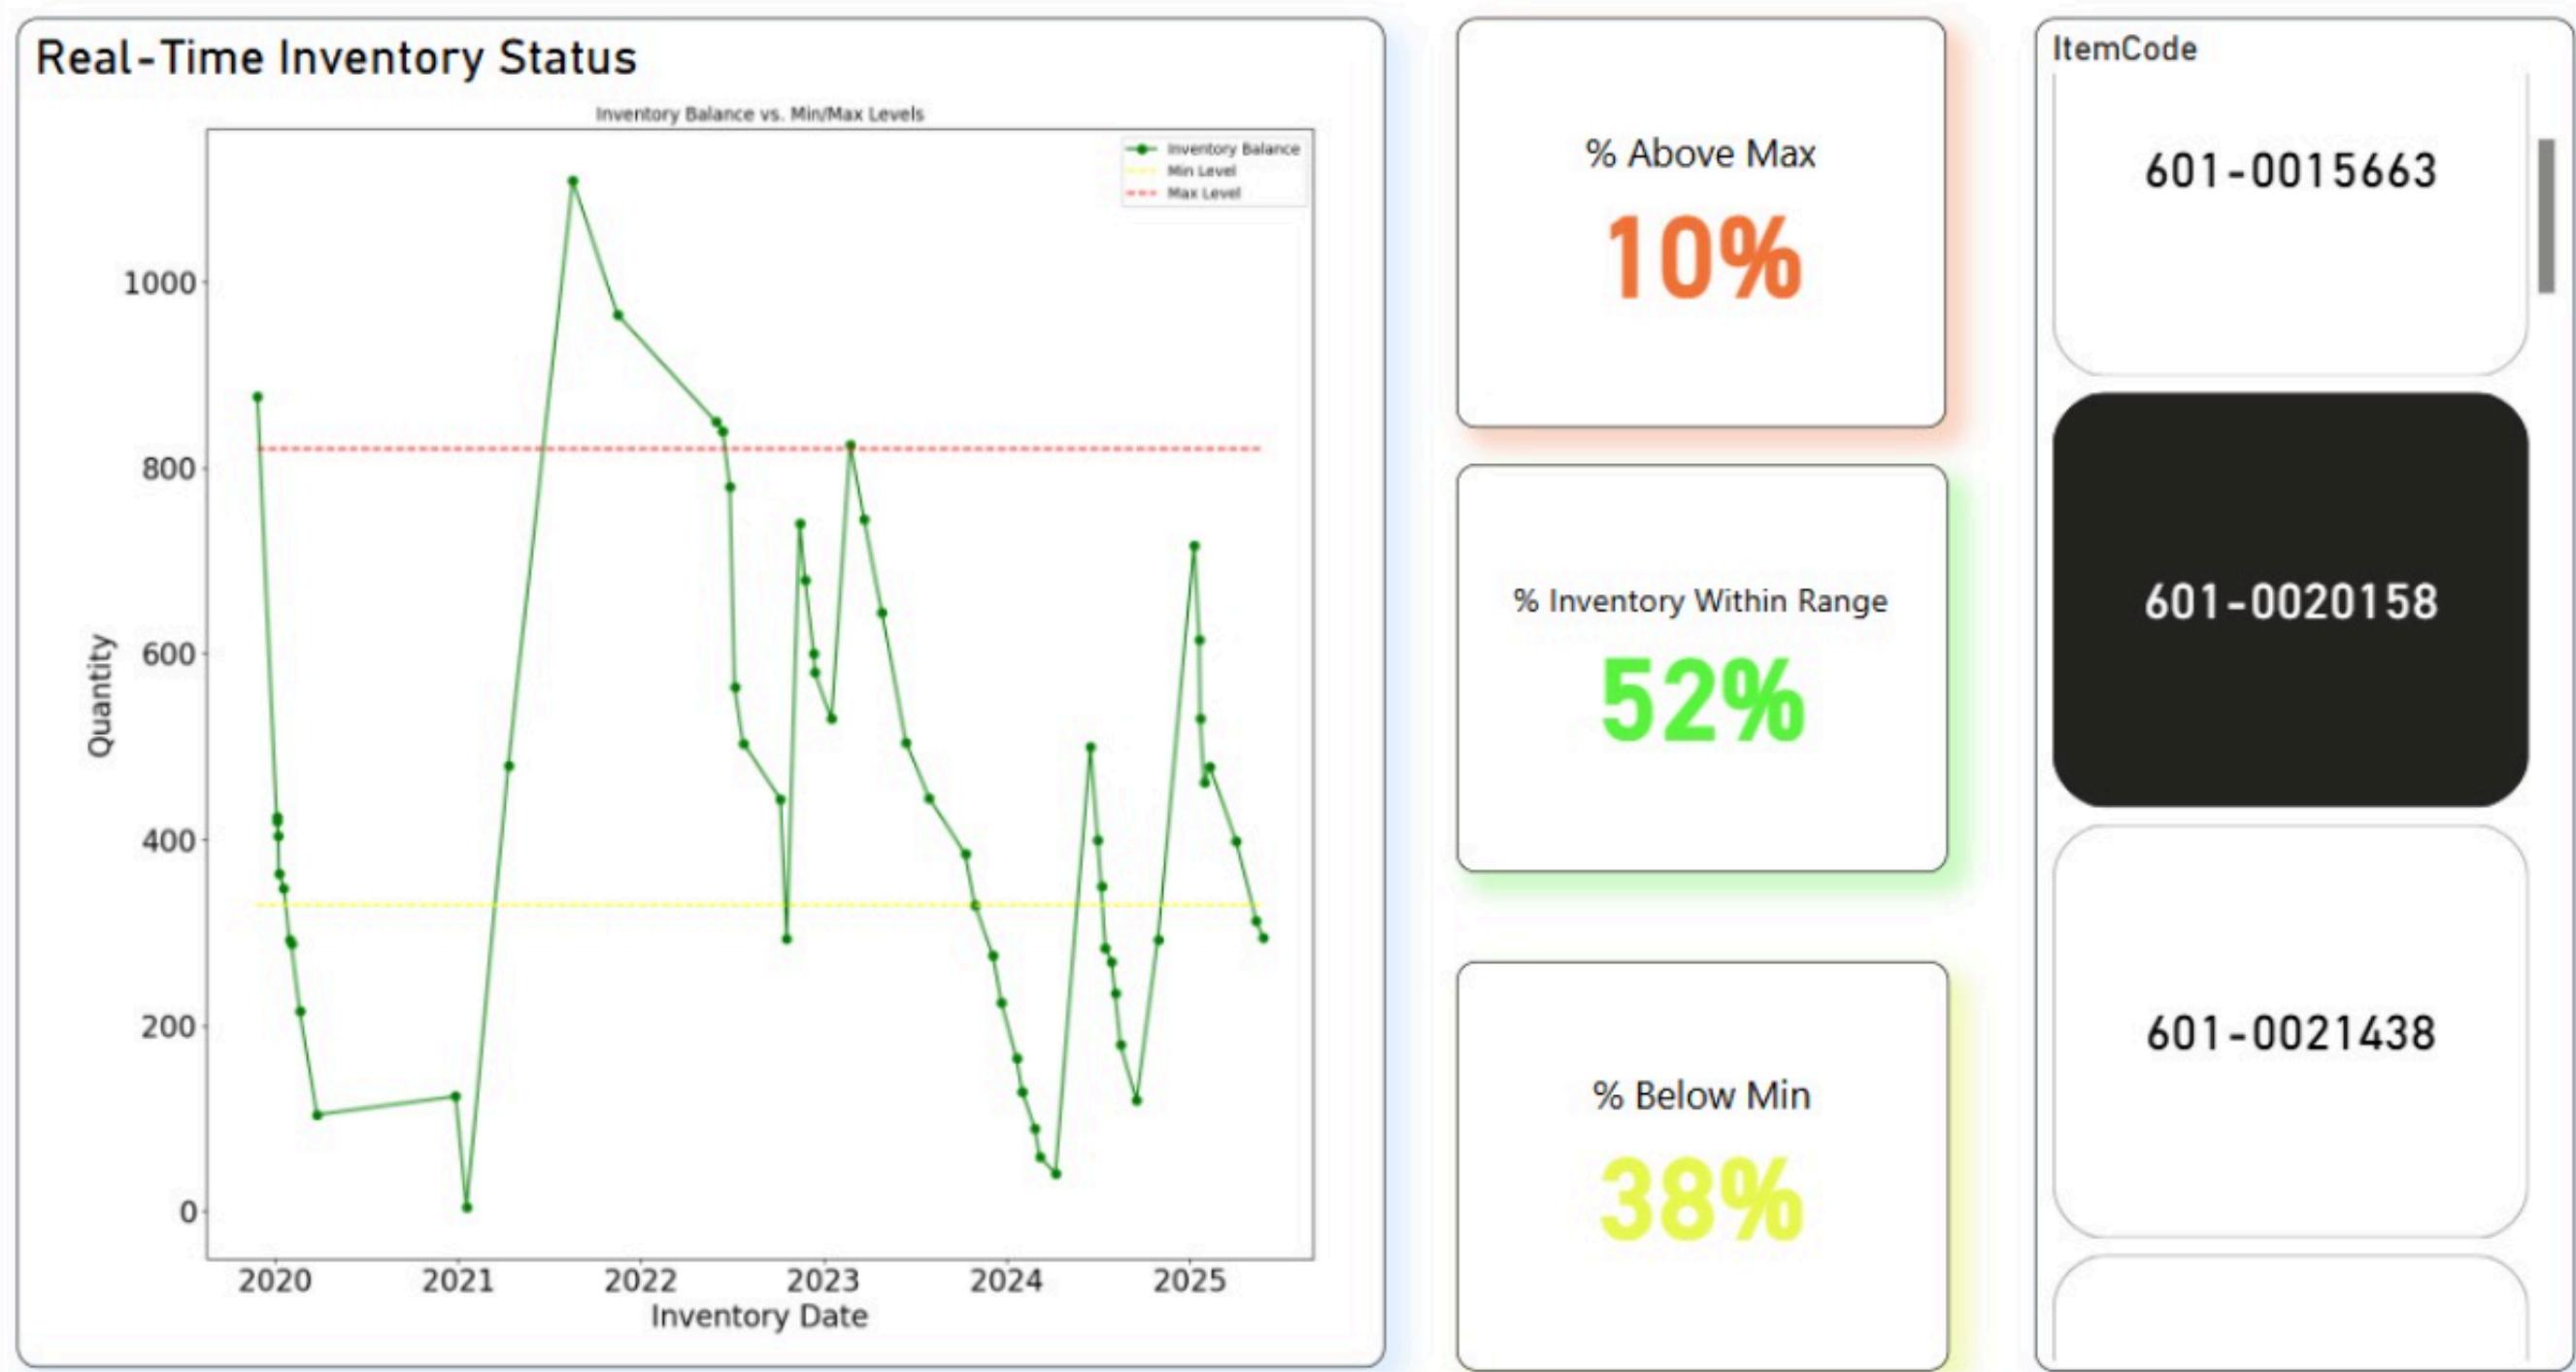
תיאור המצב הנוכחי



רקע



דשborad ניהול מלאי



סיום

דשborad -DI

חיזויים

BI

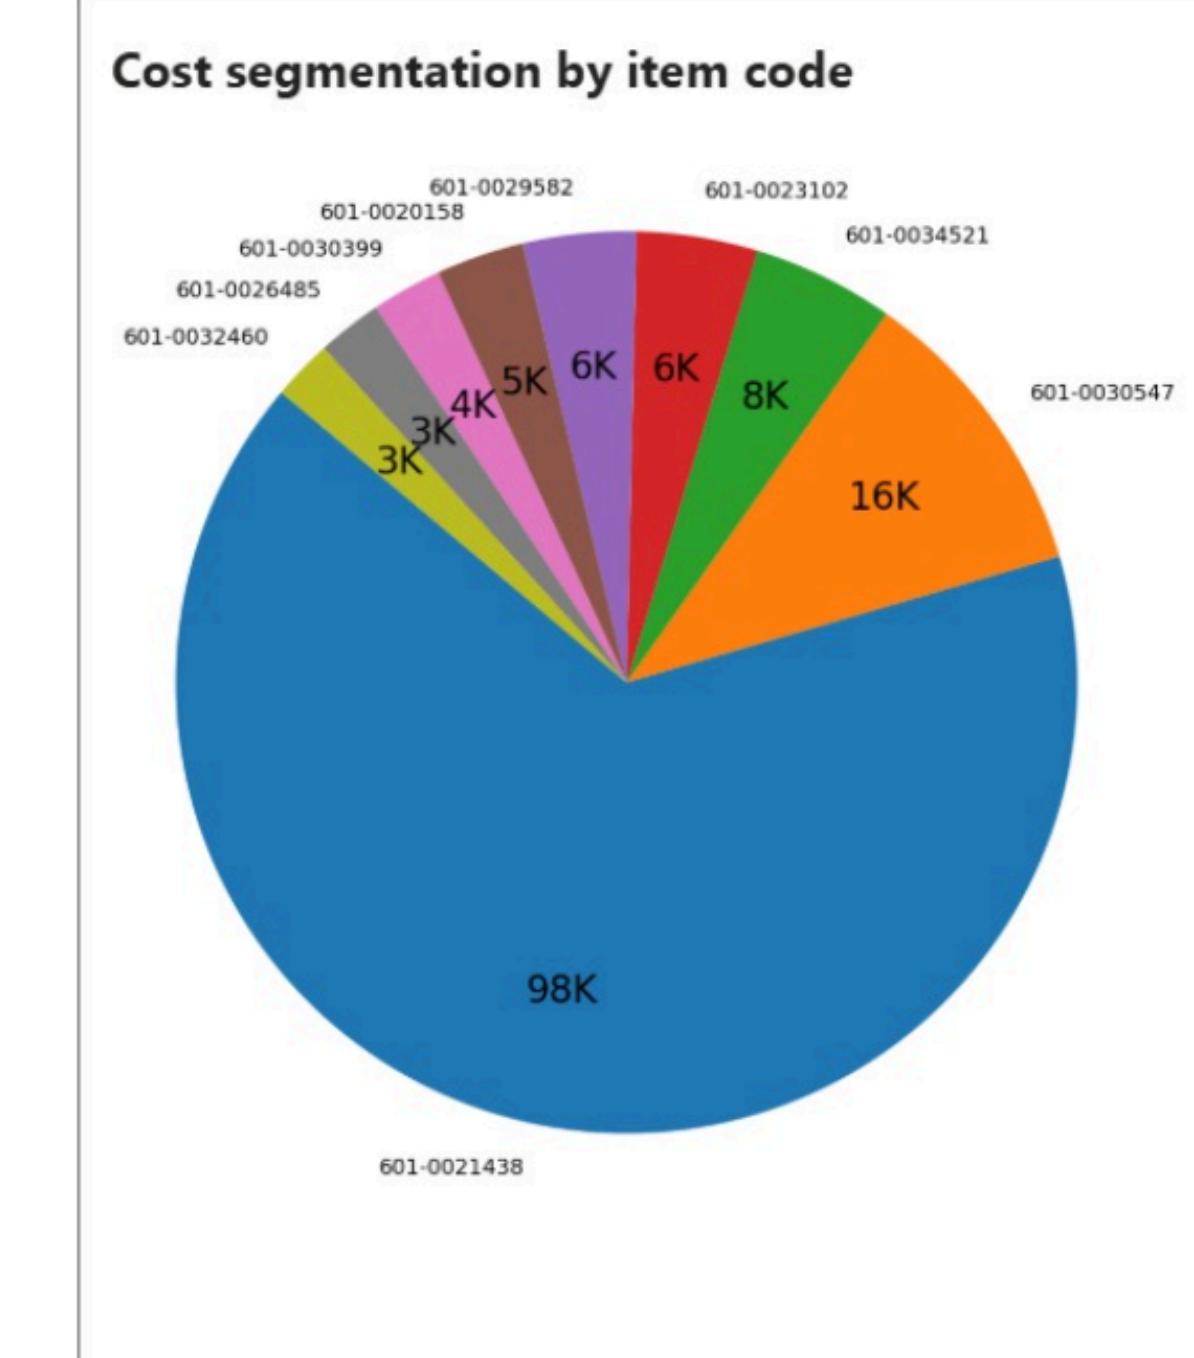
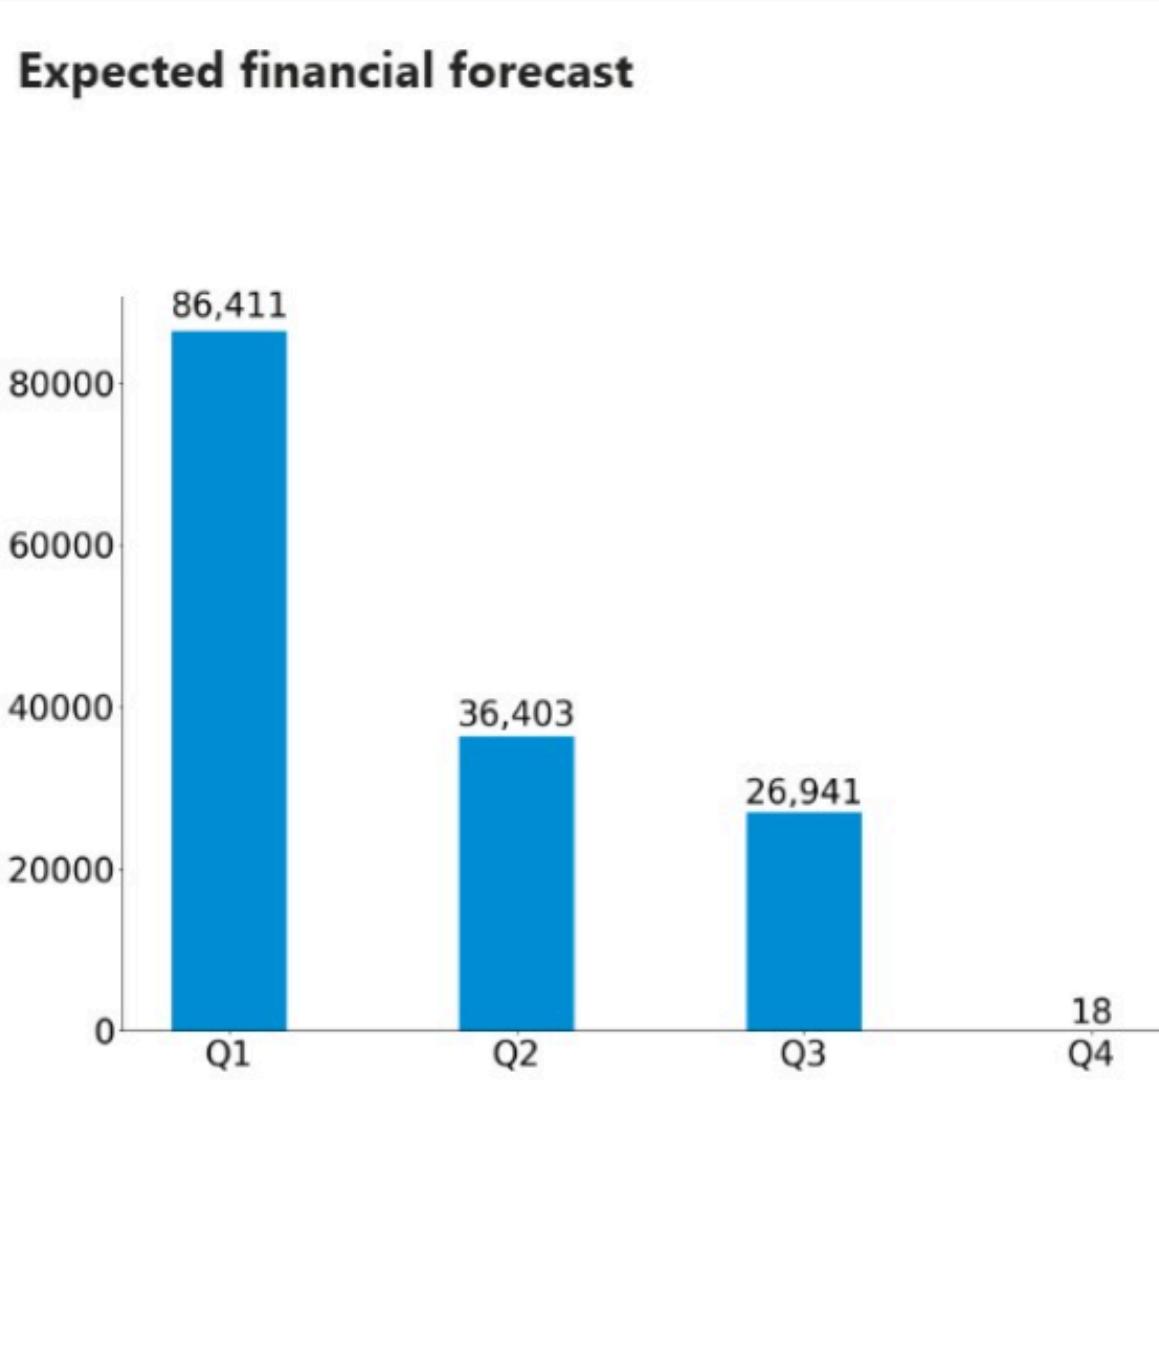
כליים לפיתוח-AI+ML

מטרות הפרויקט

תיאור המצב הנוכחי

רקע

דשborad ניהול כלכלי



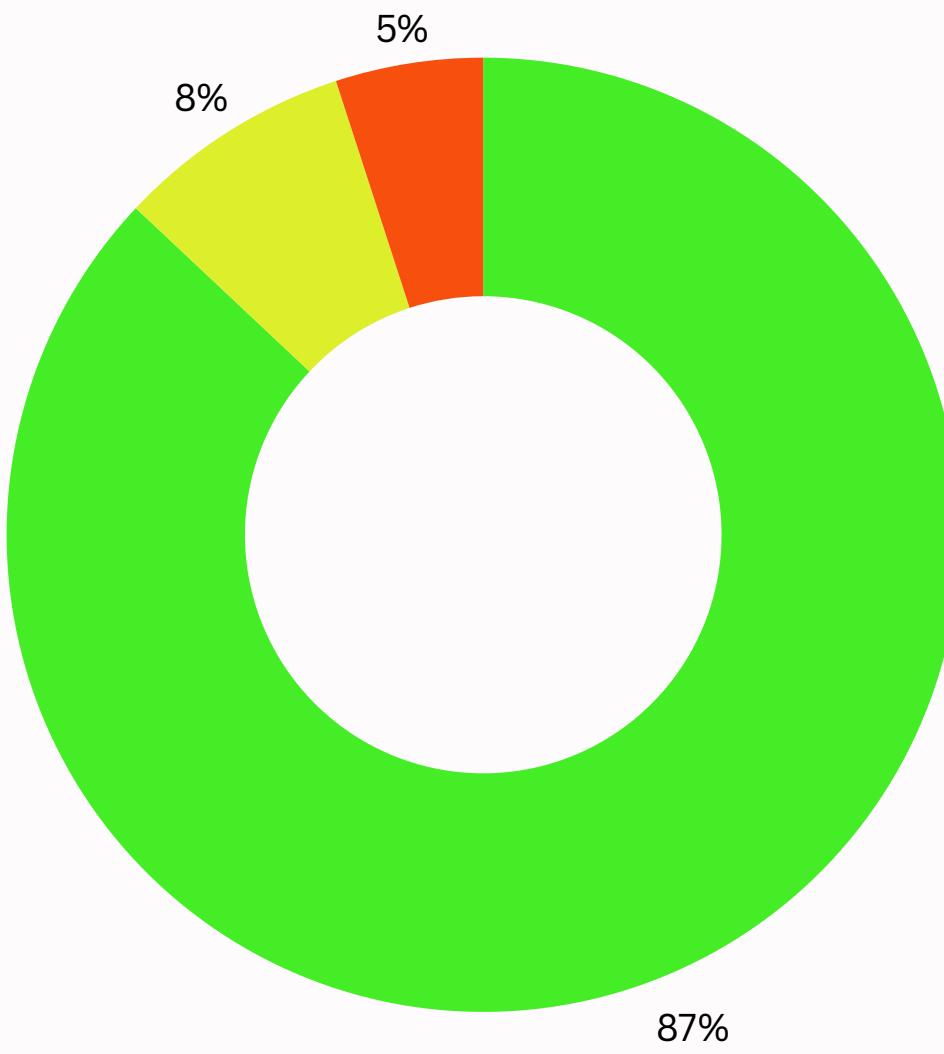


בעבודה זו, סייענו לחברת לייל את תהליכי
הרכש והמלאי, תוך מניעת הפסדים ובונית
משמעות בעבודה ייעיל.

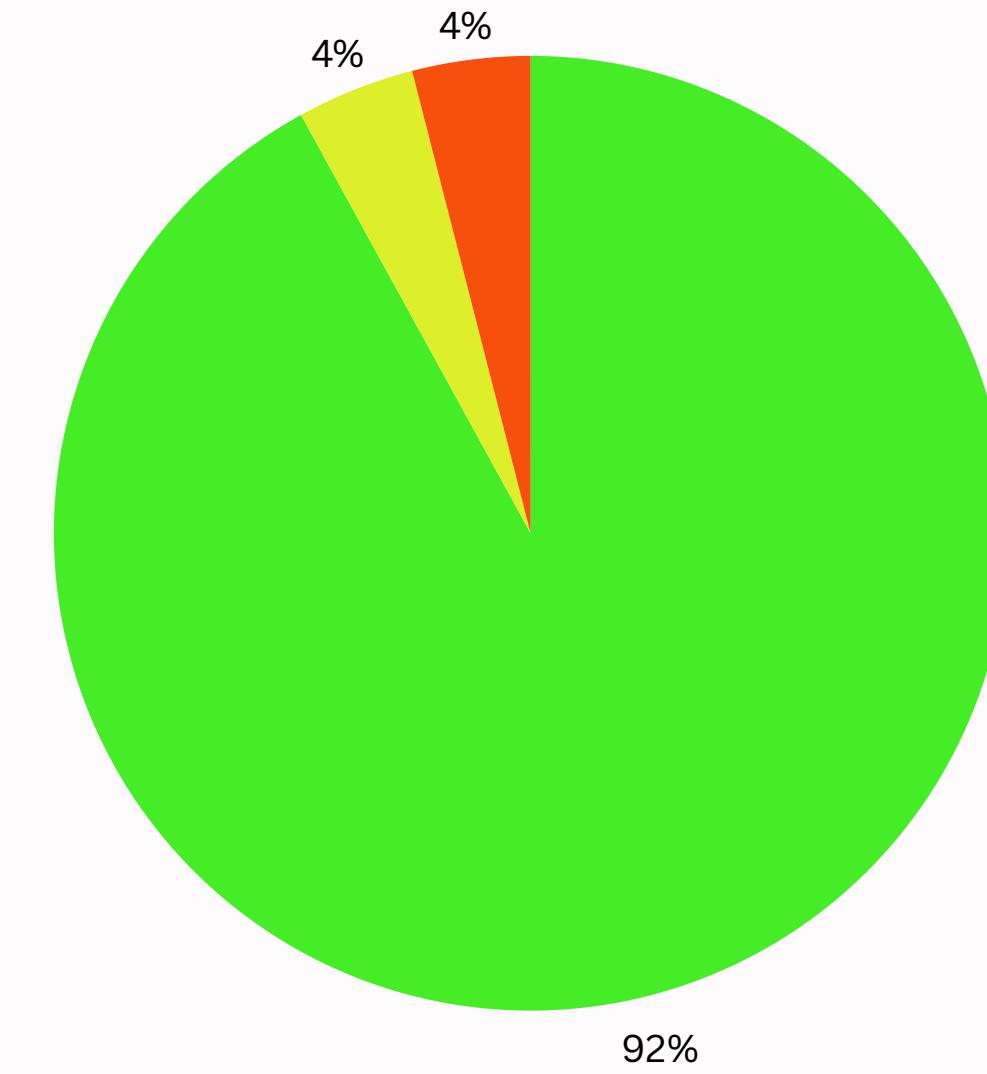
השיפור שאנו מציעים הוא 87% שהות בתוך
הגבולות, לעומת 38% קודם, וקבלת 92%
פריטים שנמצאים בתוך הגבולות בנקודת זמן
מסויימת.



המדדים לאחר השיפור



אחוז סך החריגות לאורך שנת הבדיקה



מס' הפריטים החורגים



תודה על ההקשבה!

סיום

דשبورד - DI

חיזיון

BI

כליים לפיתוחן - AI+ML

מטרות הפרויקט

תיאור המצב הנוכחי

רקע

תוספות



השלבות כלכליות - חריגות



עלות משלוח מהיר
הוא **500 דולר**.
עלות יקרה ב**300**
דולר יותר.



עלות השבתה של טכני בקו
הייצור הוא **90** דולר לשעה.
סה"כ יום עבודה של קו
מושבת:
 $8 \times 90 = 720$



עלות משטח איחסון-**80**
דולר ליום



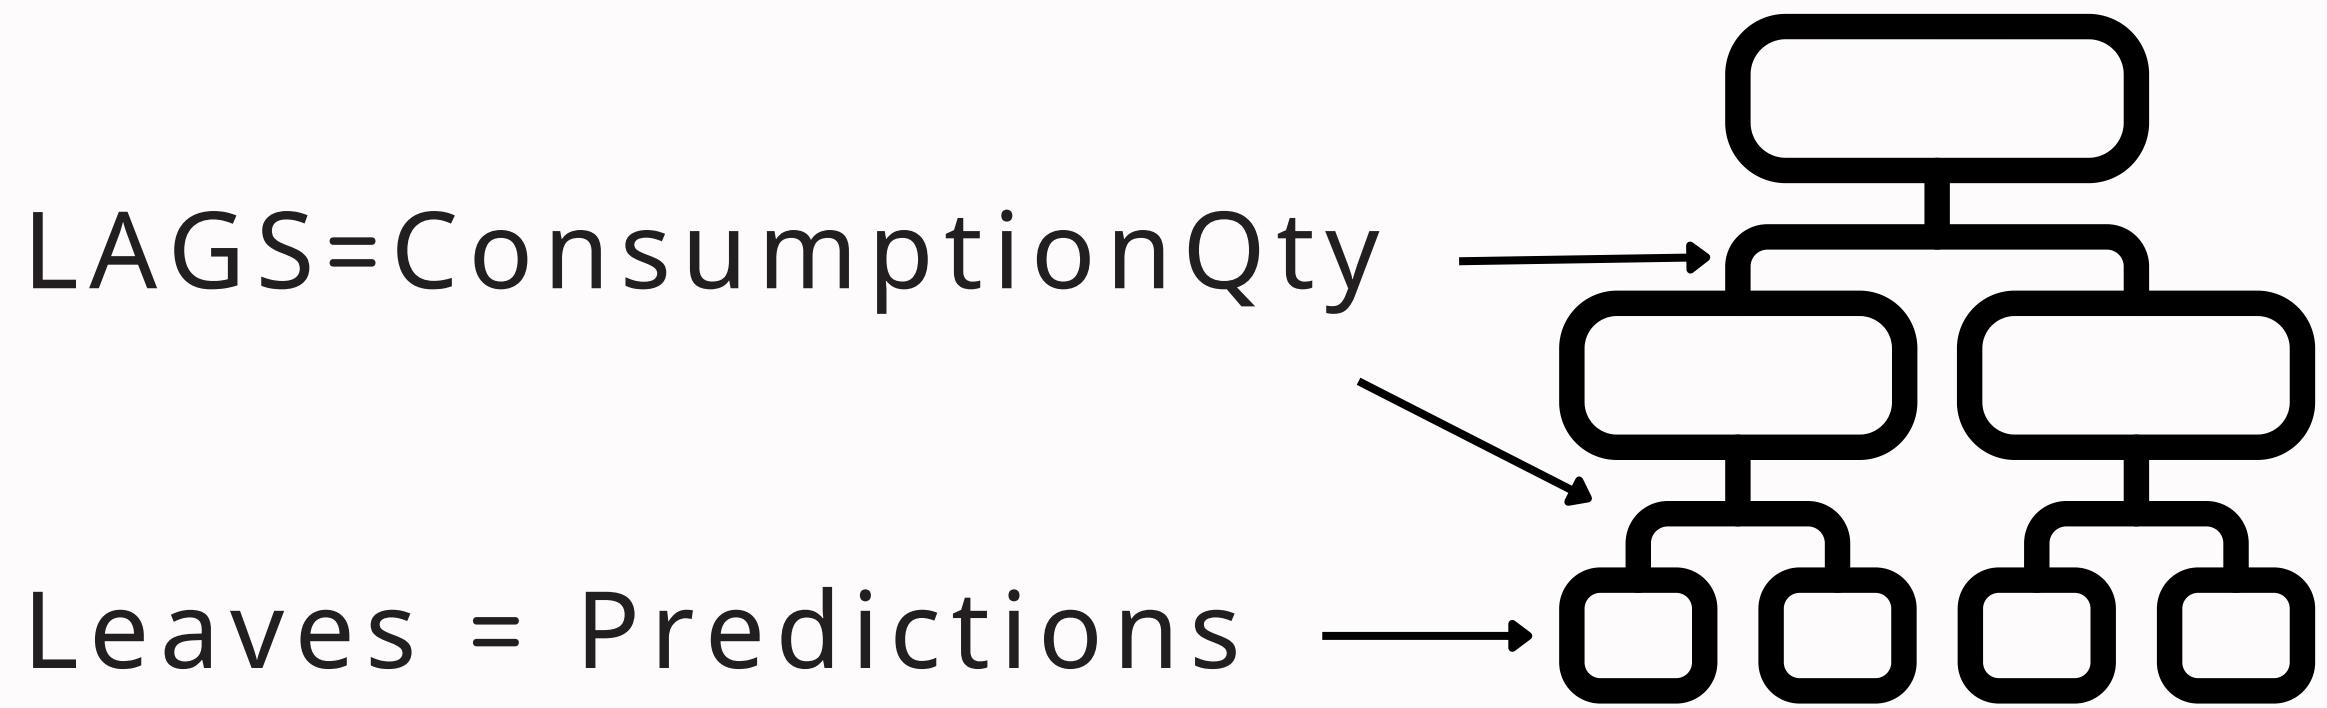
מודל prophet

$$y(t) = g(t) + s(t) + h(t) + \varepsilon t$$

רעש, חגים עונתית מגמה



מודל Xgboost



אתגרים

- **בנייה HWD** - התאמת והבנה איך בסיס הנותוניים צריך להיראות.
- **אילוצים** - קבלת תחזיות ברמה גבוהה, תוך שמירה על גבולות במינ' - מקס'.
- **הסיפוריה מוגבלת** - הנותוניים שקיבלנו אינם עשויים מספיק מה שהקשה על איבות התחזיות.
- **התאמת מודל לבן קטגוריה**.

מודל Random Forest

Features:

מספר מינימלי של דגימות לפיצול צומת= `min_samples_split`

כמה שלבים מותר לעץ "לרדת" `max_depth`=

מספר העצים ביער = `n_estimators`

שימוש בכל הליבות (מוחות) של המחשב = `n_jobs`

שליטה באקראיות = `random_state`

```
model =ARIMA(p, d, q)
```

AutoRegressive Integrated Moving Average

- .(AutoRegressive) p = כמה ערכים קודמים של הסדרה אנחנו משתמשים כדי לחזות את הערך הנוכחי).
- .(Integrated) d = כמה פעמים שעליינו לה חסיר את הערך הקודם כדי להפוך את הסדרה ללא מגמה).
- .(Moving Average) q = כמה שגיאות חיזוי מה עבר אנחנו משתמשים כדי לחזות את הערך הנוכחי).

DSD בנזינוים-תרשיים

מילון מונחים-

MIT0- טבלת כלל הפריטים

OPOR- טבלת הזמנות רכש; כותרת

POR1- טבלת הזמנות רכש; שורות

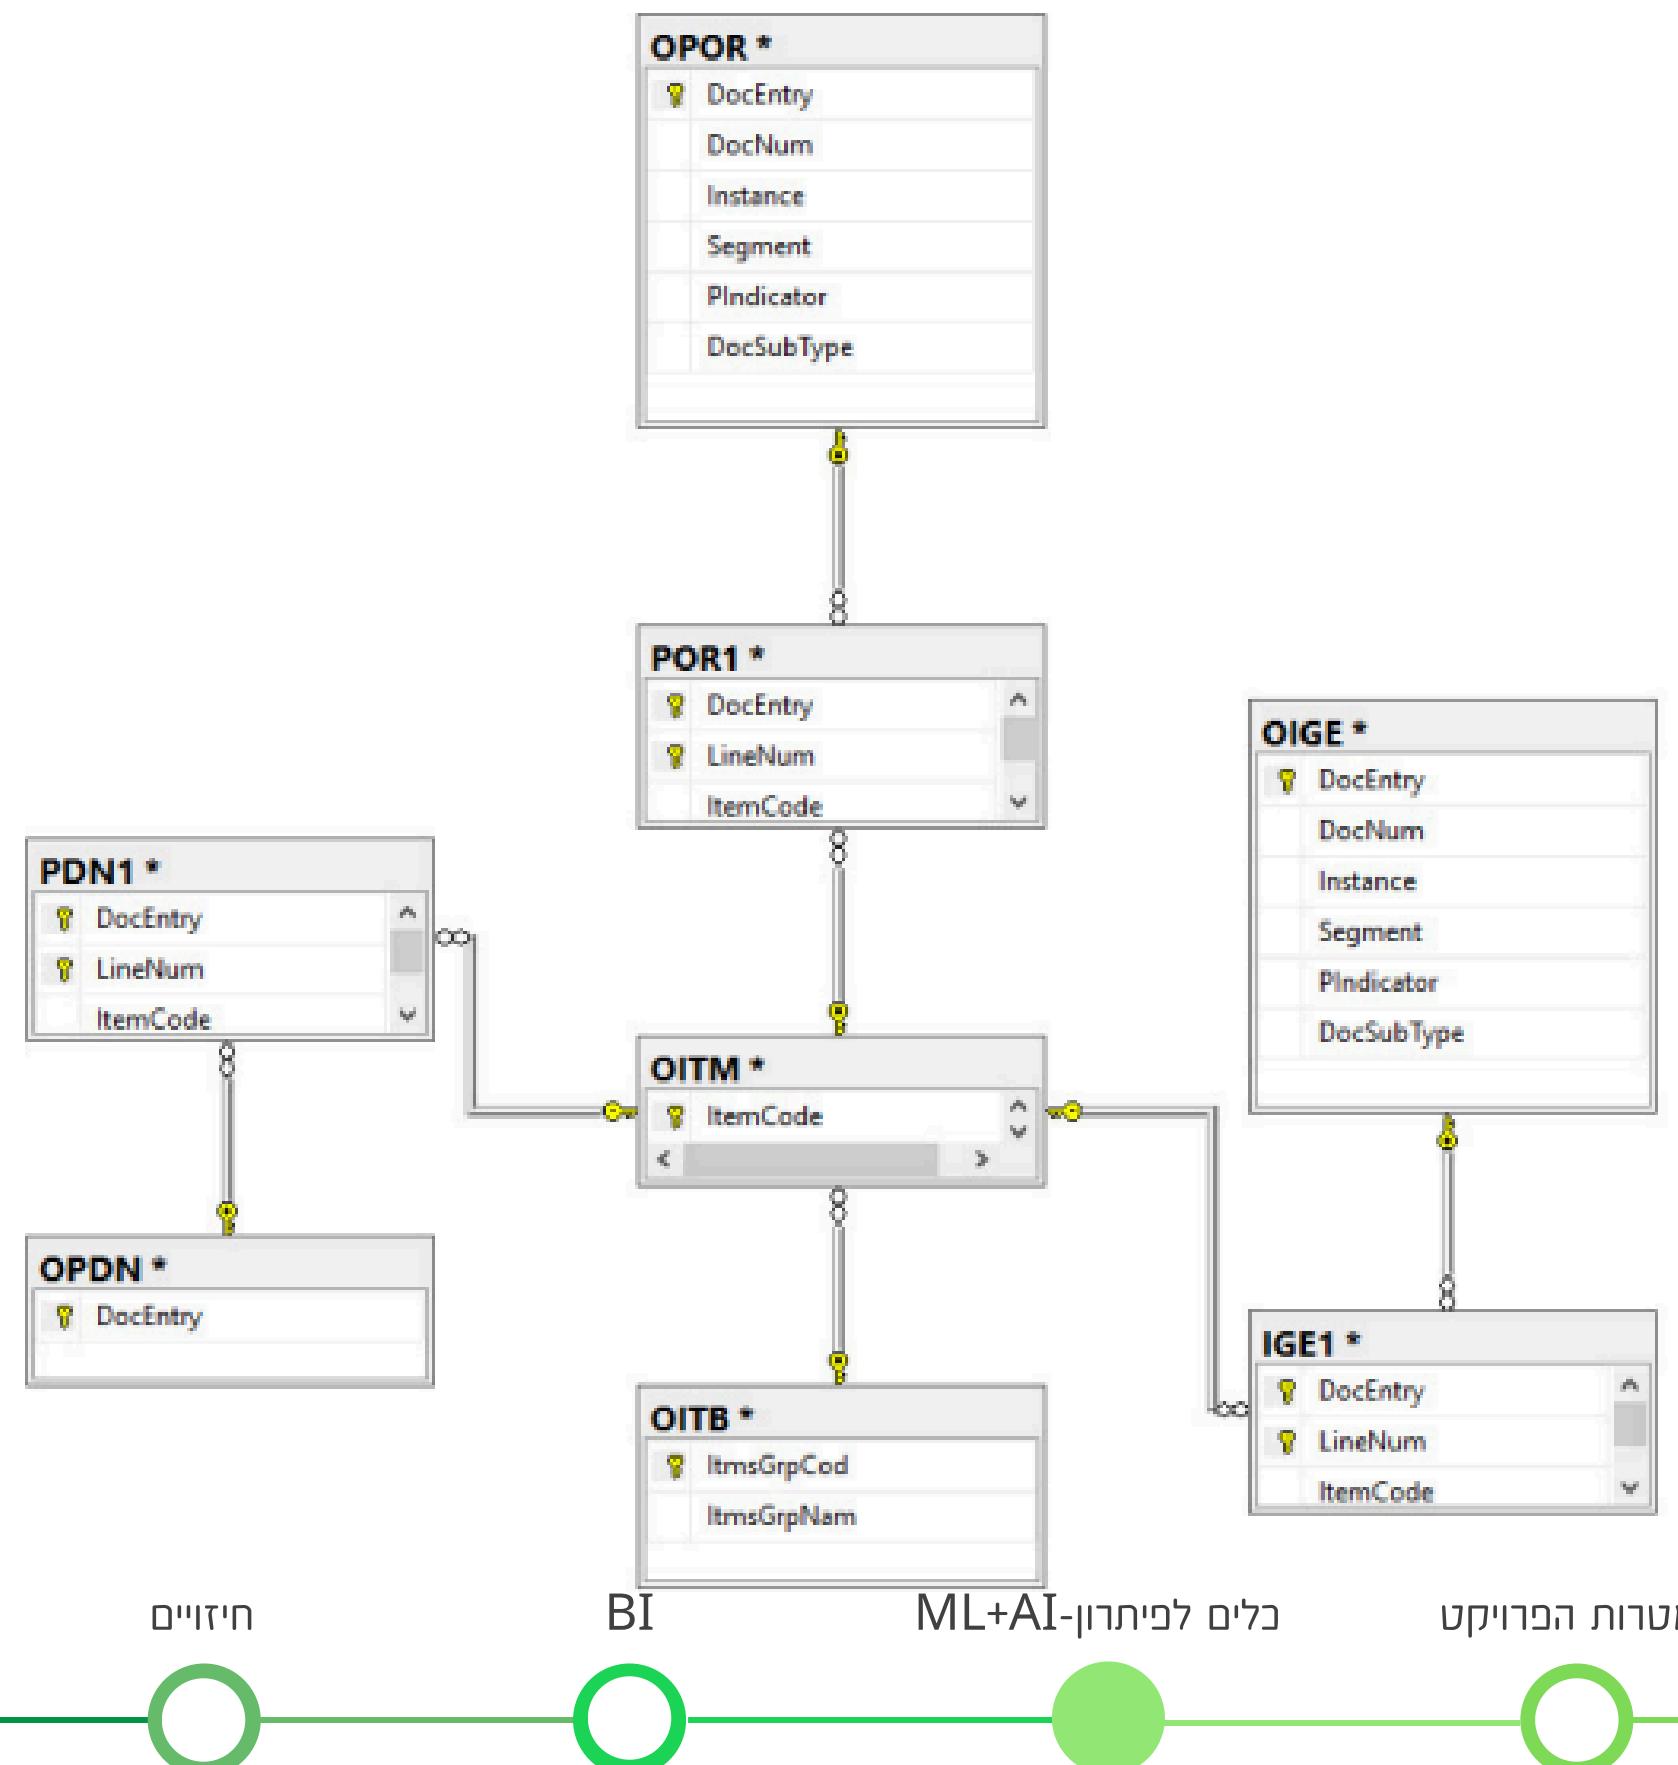
OITB- טבלת קטגוריות

OPDN- טבלת משלוח רכש; כותרת

PDN1- טבלת משלוח רכש; שורות

OIGE- טבלת ניפוקים; כותרת

IGE1- טבלת ניפוקים; שורות



סיום

דשبورד ו-DI

חיזויים

BI

קלים לפיתרון-AI+ML

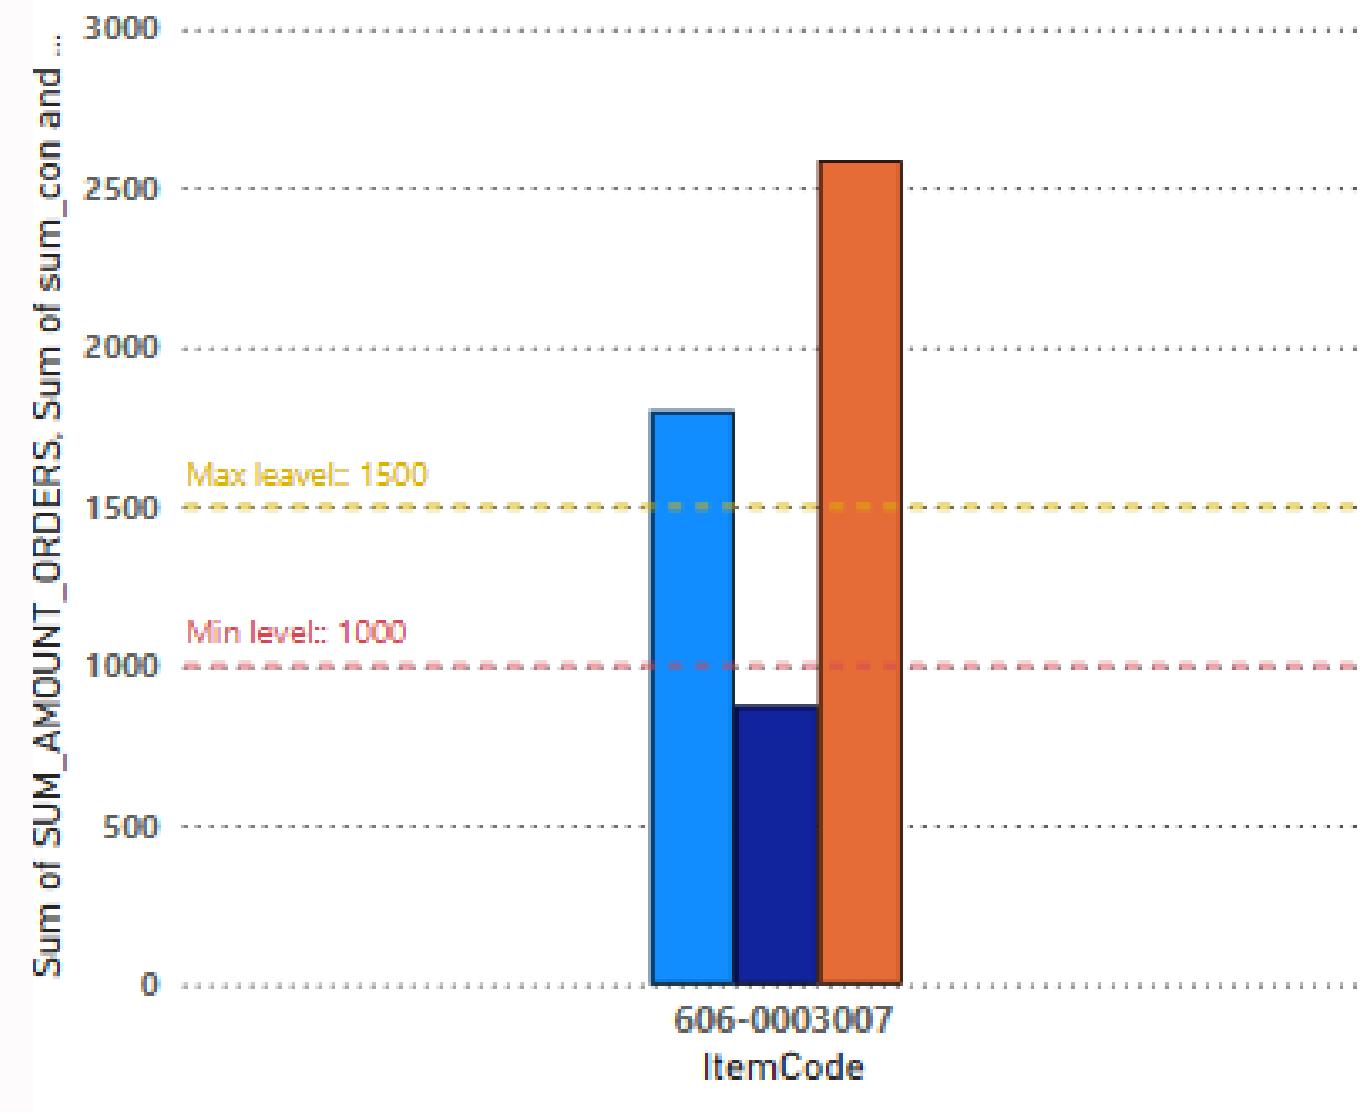
מטרות הפרויקט

תיאור המצב הנוכחי

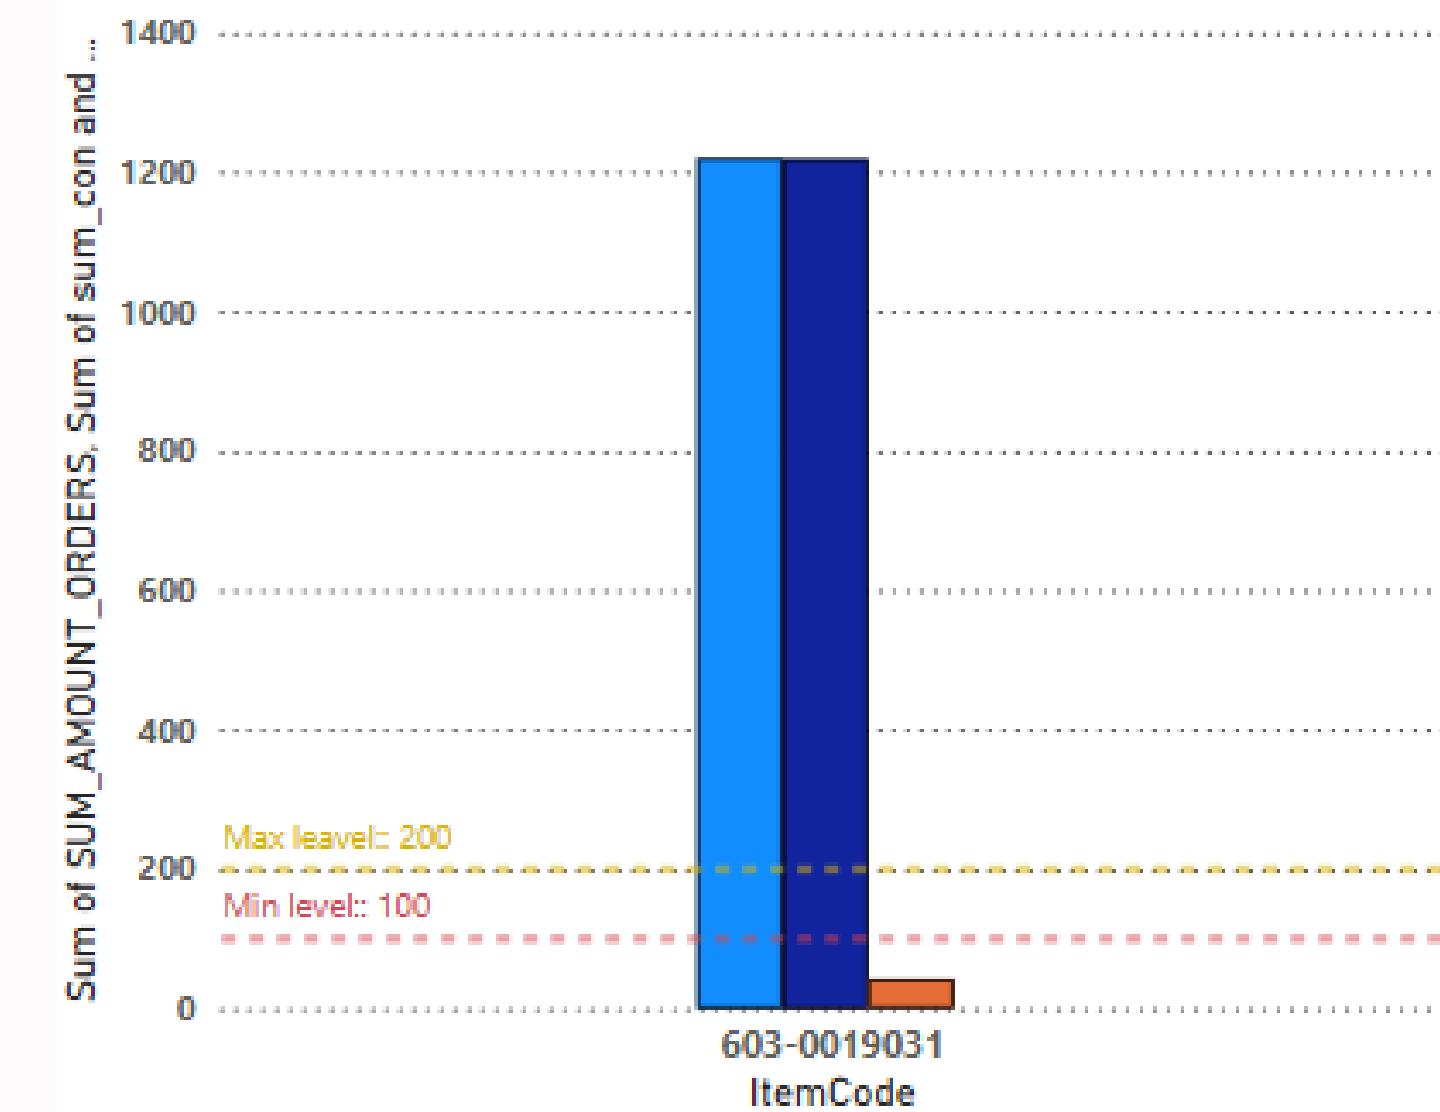
רקע

דשborad נייחולי- המחשבת הבועיה

- Ordered Units
- Units Consumed
- On Hand



מעל גבול המקסימום



מתחת לגבול המינימום

